Сопоставимые муниципалитеты: типология локальных экономик России на атрибутированной сети

Методологический отчёт. Онлайн-конкурс СберИндекса 2026, направление «Кластеризация».

1. Задача и результат

Сравнение со средним по региону мало говорит о конкретном муниципальном образовании (МО). Полезнее сравнивать МО с экономически сопоставимыми: так можно оценить потенциал, найти применимый опыт и заметить расхождение в развитии. Работа строит такое сравнение для 2 068 МО и проверяет, что оно даёт другие выводы, чем сравнение со своим регионом.

Результат состоит из трёх частей.

1. **Типология.** Пять типов локальной экономики, найденных алгоритмом KEFRiN на атрибутированной сети МО (разделы 4–6). Число типов выбрано правилом, которое проверено на синтетических сетях с известным ответом.
2. **Динамика.** Для каждого из 12 месяцев 2024 года МО отнесено к ближайшему типу с поправкой на общий для страны сдвиг; видно, кто сменил тип и кто удаляется от своего (раздел 7).
3. **Продукт.** Для каждого МО — 15 экономически сопоставимых, место МО среди них по ключевым показателям, сопоставимые МО с наибольшим ростом трат и флаг расхождения с типом (раздел 8). Продукт опубликован как датасет с ключом `territory_id` справочника СберИндекса и как интерактивный лендинг.

2. Данные

Траты жителей (СберИндекс). Средние безналичные потребительские расходы жителя МО в месяц, рубли, январь 2023 — декабрь 2024 года. Трата относится к месту жительства покупателя. Пять категорий: продовольствие, общественное питание, здоровье, транспорт, маркетплейсы, и итог «все категории»; разность итога и суммы пяти категорий названа «прочее». В панели 2 190 МО; около 500 МО в отдельные месяцы отсутствуют, потому что оценка СберИндекса для них не проходит порог качества.

Контекст МО.

- Пакет хакатона СберИндекса Data Sense 2025 (данные Росстата): население по возрасту и полу (2023–2024), миграция (2023), среднемесячная зарплата работников организаций без малого предпринимательства (2023–2024). Из них получены 7 признаков: население, доли 65+ и 0–15 лет, рост населения, миграция на 1 000 жителей, зарплата и её рост.
- Индекс доступности рынков СберИндекса (2024) и дорожные расстояния между центрами МО из пакета конкурса.
- База данных показателей муниципальных образований Росстата, 15 показателей. Для каждого взят последний год, в котором значения есть не менее чем у 70% МО от года с наибольшим покрытием. В признаки входят 11: доля городского населения, рождаемость, оборот розничной торговли, платные услуги, инвестиции в основной капитал, жилищный фонд на жителя, число рабочих мест на жителя, доли занятых в добыче, обработке, государственном управлении,

сельском хозяйстве. Остальные 4 (смертность, оборот общественного питания с покрытием 59%, продукция сельского хозяйства, фонд оплаты труда) в признаки не входят; фонд оплаты труда используется в разделе 8.

Коды показателей Росстата и фильтры разрезов записаны в `configs/base.yaml`. Отраслевая доля занятости при известном итоге и отсутствующем разделе принимается равной нулю: Росстат не публикует раздел без работников или с единичными работниками.

Ключи. МО связываются через `territory_id` справочника СберИндекса; для Росстата — через код ОКТМО из того же справочника.

3. Признаки

Признаки считаются в скользящем окне 12 месяцев. Окно с концом в месяце t охватывает месяцы t−11…t. Концы окон — 12 месяцев 2024 года. МО входит в окно, если у него есть данные не менее чем за 10 месяцев из 12; в окне, закончившемся в декабре 2024 года, таких МО 2 068.

Всего 30 признаков в трёх группах.

1. **Структура трат** — доля каждой из шести категорий в тратах за окно (6 признаков).
2. **Динамика трат** — логарифм средних трат в месяц; рост трат за последние 3 месяца к тем же месяцам прошлого года (в окнах с концом в январе и феврале 2024 года — за 1 и 2 месяца: данные начинаются с января 2023 года); сезонная амплитуда — разность максимальных и минимальных месячных трат, делённая на средние; волатильность — стандартное отклонение месячных приростов логарифма трат (4 признака).
3. **Контекст** — отношение средних трат жителя к официальной зарплате (например, траты 30 тыс. руб. при зарплате 60 тыс. руб. дают 0,5), 18 показателей Росстата из раздела 2 и индекс доступности рынков (20 признаков).

Показатели на жителя с тяжёлыми хвостами (население, зарплата, доступность рынков, оборот, услуги, инвестиции, жильё, рабочие места) логарифмируются. Пропуски заполняются медианой по стране. Все признаки стандартизуются: из значения вычитается среднее по МО и результат делится на стандартное отклонение; значения за пределами ±5 обрезаются.

4. Сеть

Узел сети — МО. Ребро соединяет МО с его k = 10 ближайшими соседями по правилу сходства; сеть делается симметричной (ребро есть, если хотя бы один из двух МО входит в соседи другого). Вес ребра — сходство, приведённое к отрезку [0, 1].

Сравнивались шесть правил сходства двух МО.

Правило	Как считается
Структура трат	косинус угла между векторами отклонений долей шести категорий от средних долей по стране
Корреляция приростов	коэффициент корреляции Пирсона месячных приростов логарифма трат
Лаговая корреляция	максимум корреляции приростов при сдвиге одного ряда относительно другого на 0, 1 или 2 месяца: учитывает, что один МО может опережать другой
DTW	сходство формы рядов трат после динамического выравнивания во времени (dynamic time warping) с окном Сакоэ — Тибы 2 месяца; расстояние d переводится в сходство exp(−d / медиана d)
Дорожная близость	exp(−расстояние по дорогам / 150 км)
Слияние	среднее рангов сходства по структуре трат и по дорожной близости

Главная мера сравнения — **однородность соседей**: насколько соседи по сети ближе друг к другу, чем случайная пара МО. Она равна 1 − (среднее расстояние между концами рёбер) / (среднее расстояние между случайными парами): 0 означает, что соседи не ближе случайных, 1 — что соседи одинаковы. Однородность по 30 признакам частично подыгрывает правилам, построенным на тратах, потому что доли трат входят и в правило, и в признаки. Поэтому она считалась ещё и только по показателям Росстата и доступности рынков, которые ни в одно правило ребра не входят.

Таблица 1. Сравнение правил ребра (окно январь — декабрь 2024 года, 2 068 МО; `outputs/network/rules_comparison.csv`).

Правило	Однородность: 30 признаков	Однородность: только Росстат	Модульность Leiden	Рёбра внутри региона	Медиана длины ребра, км
Структура трат	0,30	0,19	0,80	15%	966
Корреляция приростов	0,19	0,15	0,58	16%	1 128
Лаговая корреляция	0,19	0,15	0,58	16%	1 130
DTW	0,19	0,15	0,62	14%	1 173
Дорожная близость	0,31	0,29	0,88	76%	87
Слияние	0,36	0,30	0,83	47%	210

Правила по форме временных рядов связывают МО, мало похожие и по тратам, и по показателям Росстата: за 12 месяцев колебания трат у большинства МО определяются общими для страны сезонными и календарными эффектами. Лаговая корреляция совпадает с обычной: опережения одних МО другими на сдвигах до 2 месяцев в данных нет. Слияние структуры трат и дорожной близости даёт самых однородных соседей по обеим мерам, а связи остаются в пределах досягаемости (медиана 210 км). Оно выбрано для типологии.

5. Кластеризация

5.1. KEFRiN

KEFRiN (Shalileh, Mirkin, 2022) — расширение метода k-средних на атрибутированные сети. Каждый МО описывается двумя векторами: признаками (30 чисел) и строкой матрицы смежности сети (веса рёбер ко всем остальным МО). У каждого кластера два центра: в пространстве признаков и в пространстве строк сети. МО относится к кластеру, для которого минимальна сумма

расстояние по признакам + ξ × расстояние по сети.

Вес ξ задаёт, насколько учитывается сеть: при ξ = 0 KEFRiN совпадает с k-средних по признакам. Использована реализация авторов (репозиторий `Sorooshi/KEFRiN`, зафиксированный коммит), евклидово расстояние, инициализация k-means++.

5.2. Индексы качества

Внутренний индекс качества кластеризации (internal cluster validity index, ICVI) оценивает разбиение без эталонной разметки. Использованы семь индексов; первые три считаются по признакам, остальные — по сети.

- **SW** (силуэт, silhouette width). Для МО i: a — среднее расстояние до МО своего кластера, b — до МО ближайшего чужого; силуэт равен (b − a) / max(a, b). Например, a = 2, b = 3 дают 0,33. SW — среднее по всем МО, от −1 до 1, больше — лучше.
- **CH** (индекс Калинского — Харабаша). Отношение разброса центров кластеров вокруг общего центра к разбросу МО вокруг центров своих кластеров, с поправкой на число кластеров и МО. Больше — лучше.
- **S_Dbw**. Сумма среднего разброса внутри кластеров и плотности МО на серединах отрезков между центрами. Меньше — лучше.
- **AVI** (average isolability, средняя изолированность). Для кластера — доля веса его рёбер, которая остаётся внутри кластера; AVI — среднее по кластерам. Больше — лучше.
- **AVU** (average unifiability, средняя объединяемость). Для пары кластеров — вес рёбер между ними, делённый на вес всех внешних рёбер обоих; AVU — усреднение по парам. Меньше — лучше.
- **ANUI** — объединение двух предыдущих: 1 / (AVU + 1 / AVI). Больше — лучше.
- **MQ** (модульность). Доля веса рёбер внутри кластеров минус та доля, которая получилась бы при случайном расположении рёбер с теми же степенями узлов. Больше — лучше.

SW, CH, AVI, AVU, ANUI и MQ считаются кодом библиотеки Pattern (С. Шалилех, репозиторий `Sorooshi/Pattern`, зафиксированный коммит), S_Dbw — пакетом `s-dbw`.

5.3. Есть ли кластерная структура

Небольшой силуэт (около 0,1) бывает и тогда, когда однородное облако точек просто разрезано на части. Проверка — нулевая модель: каждый столбец матрицы признаков независимо перемешивается по МО, так что распределения признаков сохраняются, а связи между ними разрушаются. На 10 таких перестановках k-средних при K от 2 до 8 даёт силуэт не выше 0,047, а на реальных признаках — от 0,213 (K = 2) до 0,097 (K = 8), в 2,9–4,5 раза выше максимума нулевой модели; CH — 499…207 против не более 59,5 (`outputs/cluster/null_structure.csv`). Типы выделяются на фоне случайного.

5.4. Как выбрать число типов

Индексы по отдельности тянут в разные стороны, поэтому нужно правило, объединяющее их, и проверка, какое правило чаще находит верное K. Проверка — на синтетических атрибутированных

сетях с известным числом групп, по идее доклада С. Шалилеха и Е. Антонова на AI Journey 2025. Сети строились генератором из репозитория KEFRiN без изменений (`outputs/cluster/synthetic_*.csv`):

- **сильные признаки** — 60 сетей: 400 узлов; 28 признаков и 2 шумовых; истинное K = 2, 3, 4, 5, 7; параметр смешения групп по признакам pr_v = 0,7 и 0,9; сеть «лёгкая» (вероятность ребра внутри группы 0,08, между группами 0,01) и «трудная» (0,05 и 0,02); 3 повтора;
- **слабые признаки** — 24 сети: pr_v = 0,1 и 0,2, истинное K = 3 и 5, остальное так же.

На каждой сети KEFRiN (ξ = 2, как в работе) запускался при K = 2…8 и 10. Сравнивались индексы и четыре правила агрегирования: голосование SW, CH и MQ по первым местам; метод Борда — сумма рангов K по всем семи индексам; Борда по SW, CH и MQ; **Борда по блокам** — признаковый блок (средний ранг K по SW и CH) и сетевой блок (ранг по MQ) с равным весом.

Таблица 2. Доля сетей, где индекс или правило указали истинное K.

	SW	CH	MQ	S_Dbw	AVI	AVU	ANUI	Голосование	Борда, все	Борда, SW CH MQ	Борда по блокам
Сильные признаки	0,67	0,67	0,70	0,00	0,20	0,03	0,45	0,67	0,63	0,67	0,68
Слабые признаки	0,25	0,12	0,46	0,04	0,00	0,00	0,25	0,21	0,46	0,33	0,42

S_Dbw, AVI и AVU непригодны для выбора K: они монотонны по числу групп и указывают на край перебора. При сильных признаках правила почти не различаются; при истинном K = 2 и 3 SW, CH, MQ и голосование находят его во всех сетях. При слабых признаках голосование ошибается чаще остальных (0,21), потому что два из трёх голосов — признаковые индексы, а признаки неинформативны. Борда по блокам и Борда по всем индексам в среднем по двум экспериментам точнее остальных (по 0,55). Выбрана **Борда по блокам**: признаковый и сетевой взгляды весят поровну, и правило не зависит от того, сколько индексов в каждом блоке.

5.5. Вес сети ξ

KEFRiN запускался при ξ = 0, 1, 2, 5, 10, 20, 50 и K = 4 и 8 на правиле «слияние» (`outputs/cluster/kefrin_xi.csv`). При K = 8 и ξ = 2 модульность растёт с 0,37 (ξ = 0, то есть k-средних) до 0,46, изолированность AVI — с 0,51 до 0,65, а силуэт SW остаётся на уровне k-средних (0,102 против 0,100). При ξ ≥ 5 силуэт падает, при ξ = 50 разбиение вырождается (SW < 0). Выбран ξ = 2.

5.6. Сравнение методов

На синтетике — насколько метод восстанавливает истинное разбиение при известном K. Мера — скорректированный индекс Рэнда (adjusted Rand index, ARI): 1 — полное совпадение, 0 — совпадение на уровне случайного.

Таблица 3. ARI с истинным разбиением, среднее по сетям (`outputs/cluster/synthetic_methods_ari*.csv`).

Метод	Сильные признаки, лёгкая сеть	Сильные, трудная	Слабые, лёгкая	Слабые, трудная	Среднее
KEFRiN, ξ = 2	0,93	0,91	0,63	0,38	0,71
k-средних (только признаки)	1,00	1,00	0,45	0,45	0,73
Leiden (только сеть)	0,88	0,13	0,95	0,05	0,50
Спектральная (только сеть)	0,87	0,19	0,94	0,10	0,53

Методы только по сети выигрывают при чистых связях и проваливаются при зашумлённых. k-средних выигрывает при сильных признаках и проигрывает KEFRiN, когда признаки слабы, а сеть информативна. KEFRiN ни в одном условии не опускается ниже 0,38 и в среднем близок к k-средних. Для реальной сети, качество связей в которой заранее неизвестно, выбран метод без провалов.

На реальных данных — шесть методов при итоговом K = 5 на правиле «слияние», по 10 запусков с разными начальными состояниями; у KEFRiN и k-средних одинаковое число перезапусков (10).

Таблица 4. Индексы, среднее ± стандартное отклонение по 10 запускам (`outputs/cluster/methods_seeds_summary.csv`).

Метод	SW ↑	CH ↑	S_Dbw ↓	AVI ↑	AVU ↓	ANUI ↑	MQ ↑
KEFRiN, ξ = 2	0,113 ± 0,000	280 ± 0	0,855 ± 0,000	0,713 ± 0,001	0,525 ± 0,001	0,519 ± 0,001	0,493 ± 0,002
k-средних	0,113 ± 0,000	281 ± 0	0,857 ± 0,000	0,678 ± 0,000	0,527 ± 0,001	0,500 ± 0,000	0,456 ± 0,001
Смесь гауссовых распределений	0,111 ± 0,024	230 ± 5	0,889 ± 0,014	0,621 ± 0,018	0,587 ± 0,015	0,455 ± 0,010	0,388 ± 0,010
Уорд	0,156 ± 0,000	233 ± 0	0,883 ± 0,000	0,674 ± 0,000	0,548 ± 0,000	0,492 ± 0,000	0,420 ± 0,000
Leiden	0,020 ± 0,013	132 ± 15	0,875 ± 0,013	0,973 ± 0,002	0,484 ± 0,022	0,661 ± 0,011	0,733 ± 0,016
Спектральная	0,046 ± 0,000	131 ± 0	0,877 ± 0,000	0,975 ± 0,000	0,428 ± 0,000	0,688 ± 0,000	0,628 ± 0,000

KEFRiN совпадает с k-средних по признаковым индексам (SW 0,113; CH 280 против 281; S_Dbw 0,855 против 0,857) и превосходит его по сетевым (MQ 0,493 против 0,456, AVI 0,713 против 0,678). Методы только по сети дают лучшие сетевые индексы при силуэте около нуля: их кластеры связны, но внутри неоднородны по экономике. Метод Уорда даёт наибольший силуэт, но уступает KEFRiN по CH, S_Dbw и всем сетевым индексам.

6. Типология

6.1. Число типов

KEFRiN (ξ = 2, правило «слияние») запускался при K от 2 до 8 на всех 2 068 МО; K выбрано Бордой по блокам.

Таблица 5. Выбор числа типов (`outputs/typology/icvi_macro.csv`).

K	SW	CH	MQ	Ранг признакового блока	Ранг сетевого блока	Сумма
2	0,213	499	0,381	1	7	8
3	0,212	387	0,453	2	6	8
4	0,154	319	0,456	3	4	7
5	**0,113**	**280**	**0,488**	**4**	**1**	**5**
6	0,094	241	0,462	6	3	9
7	0,102	220	0,480	5,5	2	7,5
8	0,102	199	0,456	6,5	5	11,5

По отдельности SW и CH указывают на наименьшее K, модульность — на K = 5; сумма рангов двух блоков даёт K = 5. Индексы итогового разбиения: SW 0,113; CH 280; S_Dbw 0,856; AVI 0,709; AVU 0,526; ANUI 0,516; MQ 0,488.

Устойчивость. На 20 случайных подвыборках по 80% МО KEFRiN при K = 5 воспроизводит итоговые типы: ARI в медиане 0,945, от 0,58 до 0,98 (`outputs/typology/stability.csv`).

6.2. Типы

Типы пронумерованы по возрастанию медианных трат жителя. Название дано по медианам признаков (`outputs/interpret/profile_median.csv`) и по регионам, где МО типа больше всего.

Таблица 6. Типы и их медианные показатели.

	1. Стареющая глубинка	2. Удалённая периферия	3. Города и промышленные центры	4. Ресурсные территории	5. Столицы и ближнее Подмосковье	Россия
Число МО	627	554	474	154	259	2 068
Траты жителя в месяц, руб.	22 626	23 605	32 577	41 098	50 560	26 567
Доля продовольствия	47,2%	45,7%	40,4%	42,2%	31,6%	44,1%
Доля общепита	1,5%	2,0%	4,4%	3,7%	7,9%	2,6%
Доля маркетплейсов	18,8%	15,8%	15,4%	11,3%	13,1%	16,0%
Зарплата, руб.	49 839	54 939	72 090	125 854	130 499	61 572
Доля 65+	19,7%	15,5%	16,0%	10,5%	19,2%	17,1%
Доля 0–15 лет	15,7%	20,6%	18,0%	22,0%	15,7%	18,0%
Доступность рынков	344	263	330	151	566	323
Доля горожан	52%	54%	92%	76%	100%	73%
Занятость в обработке	0%	0%	23,3%	0,3%	7,5%	2,1%
Занятость в добыче	0%	0%	0%	14,1%	0%	0%
Занятость в госуправлении	14,2%	13,7%	8,4%	7,8%	2,3%	11,3%
Инвестиции на жителя, тыс. руб.	27	25	69	336	104	40
Миграция на 1 000 жителей	−6,2	−9,6	+0,6	−8,1	+15,6	−4,3

Медиана доли занятых в обработке и добыче равна 0 у типов, где у большинства МО таких работников нет или раздел не публикуется.

1. **Стареющая глубинка** — районы Центра и Поволжья (больше всего в Кировской, Нижегородской, Тверской, Саратовской, Рязанской областях). Больше всего пожилых, наибольшие доли продовольствия и маркетплейсов, самые низкие траты.
2. **Удалённая периферия** — районы Сибири и Приуралья (Алтайский край, Башкортостан, Красноярский край, Омская и Иркутская области). Низкая доступность рынков, много детей, наибольшие доли занятых в государственном управлении и сельском хозяйстве, самый большой отток жителей.
3. **Города и промышленные центры** — 59 из 67 административных центров субъектов, вошедших в типологию, и промышленные города. Почти каждый четвёртый занятый — в обработке, высокие розничный оборот и платные услуги.
4. **Ресурсные территории** — Якутия, Югра, Сахалин, Ямал. Каждый седьмой занятый — в добыче, инвестиции на жителя в 8 раз выше медианы страны, самая низкая доступность рынков.

5. **Столицы и ближнее Подмосковье** — 236 районов Москвы и Санкт-Петербурга и 23 МО других регионов, из них 16 — в Московской области. Самые высокие траты, наибольшие доли общепита и транспорта, наименьшая — продовольствия, самый большой приток жителей.

6.3. Описание типов интервальными узорными структурами

Узорная структура (pattern structure; Ganter, Kuznetsov, 2001) обобщает анализ формальных понятий на числовые признаки без перевода их в двоичные. В интервальной узорной структуре (Kaytoue, Kuznetsov и др., 2011) описание множества МО A — вектор интервалов [min, max] значений признаков по A; это замыкание A в структуре. Объём описания — все МО страны, чьи значения попадают во все интервалы.

Для каждого типа описание строится так:

1. признаки — четыре, сильнее всего отличающие тип от страны (по медиане стандартизованных значений); остаточная категория «прочее» и признаки с покрытием МО ниже 80% не используются;
2. A — ядро типа, половина его МО, ближайших к центру типа;
3. описание — интервалы признаков по ядру.

Качество описания проверяется на данных, по которым оно не строилось: МО случайно делятся пополам, описание строится по ядру типа в одной половине, а точность (доля объёма в типе) и полнота (доля типа в объёме) считаются на другой. Устойчивость — средний индекс Жаккара объёма описания по 20 подвыборкам 80% МО типа и объёма по всему типу (1 — объёмы совпадают).

Таблица 7. Описания типов (`outputs/interpret/interval_patterns.json`).

Тип	Описание	Точность	Полнота	Устойчивость
1. Стареющая глубинка	доля общепита 0,4–3,0%; зарплата 38 636–67 415 руб.; траты 18 370–28 718 руб.; доля маркетплейсов 16,1–21,6%	0,67	0,59	0,97
2. Удалённая периферия	занятость в обработке 0–12,8%; доля детей 18,3–23,9%; траты 19 050–29 350 руб.; доля общепита 0,6–3,7%	0,83	0,57	0,96
3. Города и промышленные центры	занятость в обработке 5,5–41,8%; население 19 938–304 713; волатильность трат 0,05–0,08; розничный оборот 69 237–368 754 руб. на жителя	0,67	0,43	0,94
4. Ресурсные территории	доступность рынков 117–245; рабочих мест на жителя 0,23–1,07; зарплата 93 058–203 877 руб.; занятость в добыче 0–36,5%	0,63	0,28	0,97
5. Столицы и ближнее Подмосковье	доля общепита 6,3–8,8%; траты 44 666–59 607 руб.; доля продовольствия 28,5–34,4%; доступность рынков 390–651	1,00	0,53	0,92

Описание по ядру покрывает типичных представителей типа, поэтому точность выше полноты. Объёмы описаний почти не пересекаются, кроме глубинки и периферии — двух самых близких типов: общих МО у них 147 (`interval_patterns_overlap.csv`).

6.4. Пороговые правила

Дерево решений глубины 3 (не менее 20 МО в листе), обученное различать типы по показателям в исходных единицах, правильно относит 80% МО на обучающих данных и 75% при пятикратной перекрёстной проверке (`outputs/interpret/tree_rules.txt`). Первое разбиение — траты жителя 28 082 руб. в месяц: ниже порога лежат глубинка и периферия, выше — города, ресурсные территории и столицы. Глубинку и периферию дальше разделяет доля детей (17,8%), города и столицы — доля продовольствия и доступность рынков.

6.5. Сверка с категориями МО

Лаборатория СберИндекса в итогах потребления 2025 года разделяла МО на сельские территории, пригороды агломераций, центры регионов, добывающие территории и наукограды. Для сверки категории определены по справочнику и Росстату (`outputs/interpret/lab_categories_by_type.csv`):

- 91% типа «столицы и ближнее Подмосковье» — внутригородские территории Москвы и Санкт-Петербурга;
- 49% ресурсных территорий — МО с долей занятых в добыче не меньше 15% (эта доля — один из признаков, поэтому совпадение отчасти заложено построением);
- 59 из 67 административных центров субъектов — в типе «города и промышленные центры», ещё 7 — в ресурсных территориях.

Сельские территории (доля горожан меньше 30%) по типам почти не выделяются: доля горожан известна только для 71% МО панели, и среди них мало сельских районов.

6.6. Внешняя проверка индексом мобильности

Индекс мобильности СберИндекса — медиана по жителям МО среднего расстояния от центра их покупок до точки каждой покупки, км. Он опубликован для 297 МО Северо-Западного федерального округа и в построении типов не участвовал. 278 из них сопоставлены с типологией по полному названию МО внутри регионов округа (`outputs/interpret/mobility_by_type.csv`).

Таблица 8. Медиана индекса мобильности по типам, 2024 год.

Тип	Число МО	Мобильность, км
1. Стареющая глубинка	84	0,51
2. Удалённая периферия	22	0,66
3. Города и промышленные центры	67	1,76
4. Ресурсные территории	7	1,65
5. Столицы и ближнее Подмосковье	98	4,84

Типы различаются по мобильности: тест Краскела — Уоллиса $H = 179{,}3$, $p \approx 10^{-37}$; тип объясняет 64% дисперсии рангов мобильности ($\eta^2 = 0{,}64$). Без 98 районов Санкт-Петербурга различие остаётся значимым, но слабее: $\eta^2 = 0{,}34$, $p \approx 2 \cdot 10^{-13}$. Одна доля горожан объясняет 40% дисперсии рангов (квадрат коэффициента Спирмена, 250 МО) — меньше, чем тип.

7. Динамика

Типология построена по окну январь — декабрь 2024 года; центр типа — средние признаков его МО в этом окне. В каждом из 12 окон признаки стандартизуются внутри окна: общий для страны сдвиг (например, рост доли маркетплейсов, который шёл во всех типах почти одинаково) вычитается, и остаётся положение МО относительно страны. МО относится к типу с ближайшим центром. Это же правило применяется и к опорному окну; на нём оно совпадает с типами KEFRiN у 98% МО (расходятся МО, которых в тип отнесла сеть).

Таблица 9. Переходы между типами: строка — окно с концом в январе 2024 года, столбец — в декабре 2024 года (`outputs/dynamics/transitions_first_last.csv`).

из в	1	2	3	4	5
1. Стареющая глубинка	603	2	8	0	1
2. Удалённая периферия	21	515	9	0	0
3. Города и промышленные центры	1	7	453	5	11
4. Ресурсные территории	0	2	0	150	0
5. Столицы и ближнее Подмосковье	0	0	0	0	248

От окна к окну тип сохраняют 99,3% МО. За год тип сменили 67 МО (3,2%); самые частые переходы — из периферии в глубинку (21) и из городов в столичный тип (11).

Флаг расхождения ставится МО, которое сменило тип за год, или у которого расстояние до центра своего типа растёт быстрее, чем у 95% МО (наклон линейного тренда расстояния по 12 окнам). Флаг получили 167 МО.

Проверка флага новостями. Если флаг отмечает реальные перемены в местной экономике, о таких МО должно чаще выходить новостей об экономических событиях. Для проверки взяты 167 МО с флагом и контрольная группа из 167 МО без флага, выбранных случайно с тем же распределением по типам. Для каждого МО собраны заголовки за 2024 год из поиска Google News по названию МО и региону; оставлены только заголовки, где названо само МО (1 875 заголовков по 256 МО). Каждый заголовок размечен открытой моделью GigaChat 3.1 10B-A1.8B (лицензия MIT; расчёт на GPU Kaggle, `kaggle/news_kernel.py`): категория события из девяти и признак «событие затрагивает экономику МО» — занятость, доходы, торговлю, производство или инвестиции. Разметка вручную не проверялась.

Экономическое событие хотя бы в одном заголовке нашлось у 33,5% МО с флагом и у 43,1% МО контрольной группы (точный тест Фишера, $p = 0{,}09$). Ни по одной из восьми категорий событий МО с флагом не отличаются от контрольных при $p < 0{,}05$ (`outputs/news/divergence_vs_control.csv`). Связь флага с новостями не обнаружена. У типичного МО в выборке 2–3 заголовка за год, поэтому проверка обнаружила бы только сильную связь.

8. Продукт

Для каждого из 2 068 МО по окну 2024 года.

- **Сопоставимые МО** — 15 ближайших по евклидову расстоянию в пространстве 30 стандартизованных признаков. Отдельно — до 5 ближайших из тех, до которых не больше 300 км по дорогам.
- **Потенциал** — место МО среди 16 (МО и 15 сопоставимых) по шести показателям: траты жителя, номинальный рост трат 2024 к 2023 году, доли общепита и маркетплейсов, траты к зарплате, зарплата. Для долей большее значение не лучше и не хуже: место показывает положение, а не оценку.
- **Опыт** — три сопоставимых МО с наибольшим номинальным ростом трат за год и три признака, по которым каждое из них сильнее всего отличается от выбранного МО (разность стандартизованных значений).
- **Расхождение** — флаг и траектория типа по 12 окнам.

Проверка главного тезиса. Для каждого МО вне Москвы и Санкт-Петербурга (1 825 МО) вывод «выше или ниже медианы» получен дважды: среди МО своего региона и среди 16 (МО и 15 сопоставимых). Вывод меняется у 37,7% МО по тратам жителя, у 23,9% по росту трат, у 22,2% по отношению трат к

зарплате и у 28,3% по доле маркетплейсов (`outputs/dataset/thesis_check.csv`). У типичного МО из своего региона только 3 из 15 сопоставимых. Пример — Чебоксары: траты жителя на 77% выше медианы Чувашии, но среди 16 сопоставимых (Ижевск, Киров, Омск, Уфа, Набережные Челны и др.) — 15-е место. Похожая картина у других центров регионов: Оренбург и Астрахань — на 15-м месте из 16, Ульяновск — на 14-м, Саратов — на 12-м, при тратах на 55–67% выше медианы своего региона.

Пример карточки — Комсомольск-на-Амуре (город и промышленный центр). Сопоставимые МО: Братск, Артёмовский, Ачинск, Находкинский, Нижний Тагил и ещё 10 промышленных городов Сибири, Урала и Дальнего Востока. По тратам жителя (43 257 руб. в месяц) он первый из 16, по росту трат (+17%) — восьмой; наибольший рост среди сопоставимых — у Бийска (+21%).

Траты жителей на рубль местных зарплат. Отношение средних трат жителя в месяц к фонду оплаты труда организаций МО без малого предпринимательства в расчёте на жителя в месяц (Росстат, 2024). Медиана по 1 817 МО — 2,57. По типам: глубинка 2,96, периферия 2,90, города 2,08, столицы 2,12, ресурсные территории 0,83. Больше единицы — у жителей есть деньги помимо зарплат местных организаций: пенсии и выплаты, малый бизнес, работа в другом МО. Меньше единицы — начисленное здесь тратится в другом месте, как при вахтовой работе. Это гипотеза о структуре доходов; проверить её можно только данными о доходах.

Продукт опубликован как датасет `outputs/dataset/mo_peers.csv` и JSON-карточка на каждый МО `outputs/dataset/api/<territory_id>.json`. Ключ — `territory_id` справочника СберИндекса, лицензия — CC BY-SA 4.0 с указанием источника «СберИндекс». Датасет пересчитывается одной командой при выходе нового месяца данных.

9. Обсуждение

Для 38% муниципалитетов сравнение с экономически сопоставимыми даёт другой вывод о тратах жителей, чем сравнение со своим регионом. Региональный центр, заметно опережающий свой регион, среди сопоставимых городов может оказаться в хвосте. Продукт даёт такое сравнение для любого МО вместе с ориентирами, у кого учиться. Пять типов, на которых он построен, экономически осмысленны: они совпадают с категориями лаборатории СберИндекса (столицы, центры регионов, добывающие территории), подтверждаются независимым индексом мобильности и описываются короткими интервальными описаниями с проверкой на отложенных данных.

Методический результат — выбор числа кластеров на атрибутированной сети. На синтетических сетях с известным ответом S_Dbw, AVI и AVU непригодны для выбора K, голосование индексов по первым местам ошибается при слабых признаках, а метод Борда по двум равновесным блокам (признаки и сеть) точнее остальных правил. KEFRiN с весом сети $\xi = 2$ не проваливается ни при слабых признаках, ни при зашумлённой сети; на реальных данных он совпадает с k-средних по признаковым индексам и превосходит его по сетевым.

Развивать работу стоит в четырёх направлениях. Первое — более длинные ряды трат: 24 месяца не позволяют надёжно оценить сезонность и опережение одних МО другими. Второе — матрица потоков трат между МО (где тратят жители): она дала бы правило ребра по реальным экономическим связям и проверку гипотезы о доходах вне местных зарплат. Третье — местные источники новостей вместо общего поиска: сайты администраций и районные газеты пишут о своём МО чаще, чем федеральные издания, и с ними проверка флага расхождения становится содержательной. Четвёртое — проверка продукта на данных 2025 года: предсказывают ли сопоставимые МО рост трат лучше, чем свой регион.

Ограничения. Оценка трат СберИндекса основана на данных одного банка; его доля на рынке различается по регионам, поэтому межрегиональные сравнения уровня трат надёжнее внутри типа.

Рост трат номинальный; различия региональной инфляции в 2024 году не учтены. Показатели Росстата доступны не для всех МО и заполняются медианой. Для районов Москвы и Санкт-Петербурга сопоставимые МО находятся в основном в том же городе.

10. Воспроизводимость

```
uv sync
uv run mopeers all
```

Все гиперпараметры — в `configs/base.yaml`, названия и описания типов — в `configs/types.yaml`. Исходные данные скачиваются из официальных источников, пакет Data Sense проверяется по SHA-256. Код алгоритмов жюри (KEFRiN, генератор синтетики, метрики Pattern) скачивается с зафиксированных коммитов. Случайные запуски фиксируются `seed: 0`. Полный прогон после скачивания данных занимает около 35 минут на ноутбуке без GPU; прогон с нуля в чистой копии репозитория воспроизводит побайтно все таблицы и наборы данных в `outputs/`.

Литература

1. Shalileh S., Mirkin B. Community partitioning over feature-rich networks using an extended k-means method // Entropy. 2022. Vol. 24, No. 5. P. 626.
2. Ganter B., Kuznetsov S. O. Pattern structures and their projections // Conceptual Structures: Broadening the Base (ICCS 2001). LNCS 2120. Springer, 2001. P. 129–142.
3. Kaytoue M., Kuznetsov S. O., Napoli A., Duplessis S. Mining gene expression data with pattern structures in formal concept analysis // Information Sciences. 2011. Vol. 181, No. 10. P. 1989–2001.
4. Traag V. A., Waltman L., van Eck N. J. From Louvain to Leiden: guaranteeing well-connected communities // Scientific Reports. 2019. Vol. 9. 5233.
5. Rousseeuw P. J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis // Journal of Computational and Applied Mathematics. 1987. Vol. 20. P. 53–65.
6. Caliński T., Harabasz J. A dendrite method for cluster analysis // Communications in Statistics. 1974. Vol. 3, No. 1. P. 1–27.
7. Halkidi M., Vazirgiannis M. Clustering validity assessment: finding the optimal partitioning of a data set // Proceedings of IEEE ICDM. 2001. P. 187–194.
8. Newman M. E. J. Modularity and community structure in networks // PNAS. 2006. Vol. 103, No. 23. P. 8577–8582.
9. Hubert L., Arabie P. Comparing partitions // Journal of Classification. 1985. Vol. 2. P. 193–218.
10. Доклад С. Шалилеха и Е. Антонова на AI Journey 2025 о поведении индексов качества кластеризации атрибутированных сетей на синтетических данных (сообщение канала «Команда СберИндекса» от 03.12.2025).