Сопоставимые муниципалитеты: типология локальных экономик России на атрибутированной сети

Методологический отчёт. Онлайн-конкурс СберИндекса 2026, направление «Кластеризация».

1. Задача и результат

Сравнение со средним по региону мало говорит о конкретном муниципальном образовании (МО). Полезнее сравнивать МО с экономически сопоставимыми: так можно оценить потенциал, найти применимый опыт и заметить расхождение в развитии. Работа строит такое сравнение для 2 068 МО и проверяет, что оно даёт другие выводы, чем сравнение со своим регионом.

Результат состоит из трёх частей.

1. **Типология.** Пять типов локальной экономики, найденных алгоритмом KEFRiN на атрибутированной сети МО (разделы 4–6). Число типов выбрано правилом, которое проверено на синтетических сетях с известным ответом.
2. **Динамика.** Для каждого из 12 месяцев 2024 года МО отнесено к ближайшему типу с поправкой на общий для страны сдвиг; видно, кто сменил тип и кто удаляется от своего (раздел 7).
3. **Продукт.** Для каждого МО — 15 экономически сопоставимых, место МО среди них по ключевым показателям, сопоставимые МО с наибольшим ростом трат и флаг расхождения с типом (раздел 8). Продукт опубликован как датасет с ключом `territory_id` справочника СберИндекса и как интерактивный лендинг.

Типы проверены данными, которые в их построении не участвовали: индексом мобильности СберИндекса, реестром малого и среднего бизнеса ФНС, ночной освещённостью со спутника, перечнем моногородов и новостями (раздел 9).

2. Данные

Траты жителей (СберИндекс). Средние безналичные потребительские расходы жителя МО в месяц, рубли, январь 2023 — декабрь 2024 года. Трата относится к месту жительства покупателя. Пять категорий: продовольствие, общественное питание, здоровье, транспорт, маркетплейсы, и итог «все категории»; разность итога и суммы пяти категорий названа «прочее». В панели 2 190 МО; около 500 МО в отдельные месяцы отсутствуют, потому что оценка СберИндекса для них не проходит порог качества. Агрегированные траты по банковским картам используются как оперативная мера потребления на малых территориях и в других странах, например в базе Opportunity Insights по округам США [1].

Контекст МО.

- Пакет хакатона СберИндекса Data Sense 2025 (данные Росстата): население по возрасту и полу (2023–2024), миграция (2023), среднемесячная зарплата работников организаций без малого предпринимательства (2023–2024). Из них получены 7 признаков: население, доли 65+ и 0–15 лет, рост населения, миграция на 1 000 жителей, зарплата и её рост.

- Индекс доступности рынков СберИндекса (2024) и дорожные расстояния между центрами МО из пакета конкурса.
- База данных показателей муниципальных образований Росстата, 15 показателей. Для каждого взят последний год, в котором значения есть не менее чем у 70% МО от года с наибольшим покрытием. В признаки входят 11: доля городского населения, рождаемость, оборот розничной торговли, платные услуги, инвестиции в основной капитал, жилищный фонд на жителя, число рабочих мест на жителя, доли занятых в добыче, обработке, государственном управлении, сельском хозяйстве. Остальные 4 (смертность, оборот общественного питания с покрытием 59%, продукция сельского хозяйства, фонд оплаты труда) в признаки не входят; фонд оплаты труда используется в разделе 8.

Коды показателей Росстата и фильтры разрезов записаны в `configs/base.yaml`. Для долей населения и занятых Росстат публикует итог и части. Если итог известен, а части нет, доля принимается равной нулю: строки «городское население» нет у района без городов, раздела занятости нет, если работников в отрасли нет или они единичны. Так доля горожан известна для 98,6% МО.

Ключи. МО связываются через `territory_id` справочника СберИндекса; для Росстата — через код ОКТМО из того же справочника.

Снимок данных. Все исходные файлы на 27.09.2026 опубликованы в релизе репозитория `data-2026-09-27` с контрольной суммой SHA-256. Шаг `download` берёт снимок, если официальный источник недоступен.

3. Признаки

Признаки считаются в скользящем окне 12 месяцев. Окно с концом в месяце t охватывает месяцы t−11…t. Концы окон — 12 месяцев 2024 года. МО входит в окно, если у него есть данные не менее чем за 10 месяцев из 12; в окне, закончившемся в декабре 2024 года, таких МО 2 068.

Всего 30 признаков в трёх группах.

1. **Структура трат** — доля каждой из шести категорий в тратах за окно (6 признаков).
2. **Динамика трат** — логарифм средних трат в месяц; рост трат за последние 3 месяца к тем же месяцам прошлого года (в окнах с концом в январе и феврале 2024 года — за 1 и 2 месяца: данные начинаются с января 2023 года); сезонная амплитуда — разность максимальных и минимальных месячных трат, делённая на средние; волатильность — стандартное отклонение месячных приростов логарифма трат (4 признака).
3. **Контекст** — отношение средних трат жителя к официальной зарплате (например, траты 30 тыс. руб. при зарплате 60 тыс. руб. дают 0,5), 18 показателей Росстата из раздела 2 и индекс доступности рынков (20 признаков).

Показатели на жителя с тяжёлыми хвостами (население, зарплата, доступность рынков, оборот, услуги, инвестиции, жильё, рабочие места) логарифмируются. Все признаки стандартизуются: из значения вычитается среднее по МО и результат делится на стандартное отклонение. Оставшиеся пропуски показателей Росстата заполняются методом k ближайших соседей (KNNImputer, k = 10; Troyanskaya и др. [2]): пропуск получает среднее значение признака у 10 МО, ближайших по известным признакам. Значения за пределами ±5 стандартных отклонений обрезаются.

4. Сеть

Узел сети — МО. Ребро соединяет МО с его k = 10 ближайшими соседями по правилу сходства; сеть делается симметричной (ребро есть, если хотя бы один из двух МО входит в соседи другого). Вес ребра — сходство, приведённое к отрезку [0, 1]. Для сравнения правил сеть разбивается на сообщества алгоритмом Leiden [3], и считается модульность разбиения (раздел 5.2).

Сравнивались шесть правил сходства двух МО.

Правило	**Как считается**
Структура трат	косинус угла между векторами отклонений долей шести категорий от средних долей по стране
Корреляция приростов	коэффициент корреляции Пирсона месячных приростов логарифма трат
Лаговая корреляция	максимум корреляции приростов при сдвиге одного ряда относительно другого на 0, 1 или 2 месяца: учитывает, что один МО может опережать другой
DTW	сходство формы рядов трат после динамического выравнивания во времени (dynamic time warping) с окном Сакоэ — Тибы [4] 2 месяца; расстояние d переводится в сходство exp(−d / медиана d)
Дорожная близость	exp(−расстояние по дорогам / 150 км)
Слияние	среднее рангов сходства по структуре трат и по дорожной близости

Главная мера сравнения — **однородность соседей**: насколько соседи по сети ближе друг к другу, чем случайная пара МО. Она равна 1 − (среднее расстояние между концами рёбер) / (среднее расстояние между случайными парами): 0 означает, что соседи не ближе случайных, 1 — что соседи одинаковы. Однородность по 30 признакам частично подыгрывает правилам, построенным на тратах, потому что доли трат входят и в правило, и в признаки. Поэтому она считалась ещё и только по показателям Росстата и доступности рынков, которые ни в одно правило ребра не входят.

Таблица 1. Сравнение правил ребра (окно январь — декабрь 2024 года, 2 068 МО; `outputs/network/rules_comparison.csv`).

Правило	**Однородность: 30 признаков**	**Однородность: только Росстат**	**Модульность Leiden**	**Рёбра внутри региона**	**Медиана длины ребра, км**
Структура трат	0,31	0,23	0,80	15%	966
Корреляция приростов	0,20	0,17	0,58	16%	1 128
Лаговая корреляция	0,20	0,17	0,58	16%	1 130
DTW	0,20	0,16	0,62	14%	1 173
Дорожная близость	0,31	0,29	0,88	76%	87
Слияние	0,37	0,31	0,83	47%	210

Правила по форме временных рядов связывают МО, мало похожие и по тратам, и по показателям Росстата: за 12 месяцев колебания трат у большинства МО определяются общими для страны сезонными и календарными эффектами. Лаговая корреляция совпадает с обычной: опережения одних

МО другими на сдвигах до 2 месяцев в данных нет. Слияние структуры трат и дорожной близости даёт самых однородных соседей по обеим мерам, а связи остаются в пределах досягаемости (медиана 210 км). Оно выбрано для типологии.

5. Кластеризация

5.1. KEFRiN

KEFRiN (Shalileh, Mirkin, 2022 [5]) — расширение метода k-средних на атрибутированные сети. Каждый МО описывается двумя векторами: признаками (30 чисел) и строкой матрицы смежности сети (веса рёбер ко всем остальным МО). У каждого кластера два центра: в пространстве признаков и в пространстве строк сети. МО относится к кластеру, для которого минимальна сумма

расстояние по признакам + ξ × расстояние по сети.

Вес ξ задаёт, насколько учитывается сеть: при ξ = 0 KEFRiN совпадает с k-средних по признакам. Использована реализация авторов (репозиторий `Sorooshi/KEFRiN`, зафиксированный коммит), евклидово расстояние, инициализация k-means++ [6].

5.2. Индексы качества

Внутренний индекс качества кластеризации (internal cluster validity index, ICVI) оценивает разбиение без эталонной разметки. Использованы семь индексов; первые три считаются по признакам, остальные — по сети.

- **SW** (силуэт, silhouette width [7]). Для МО i: a — среднее расстояние до МО своего кластера, b — до МО ближайшего чужого; силуэт равен (b − a) / max(a, b). Например, a = 2, b = 3 дают 0,33. SW — среднее по всем МО, от −1 до 1, больше — лучше.
- **CH** (индекс Калинского — Харабаша [8]). Отношение разброса центров кластеров вокруг общего центра к разбросу МО вокруг центров своих кластеров, с поправкой на число кластеров и МО. Больше — лучше.
- **S_Dbw** [9]. Сумма среднего разброса внутри кластеров и плотности МО на серединах отрезков между центрами. Меньше — лучше.
- **AVI** (average isolability, средняя изолированность). Для кластера — доля веса его рёбер, которая остаётся внутри кластера; AVI — среднее по кластерам. Больше — лучше.
- **AVU** (average unifiability, средняя объединяемость). Для пары кластеров — вес рёбер между ними, делённый на вес всех внешних рёбер обоих; AVU — усреднение по парам. Меньше — лучше.
- **ANUI** — объединение двух предыдущих: 1 / (AVU + 1 / AVI). Больше — лучше.
- **MQ** (модульность [10]). Доля веса рёбер внутри кластеров минус та доля, которая получилась бы при случайном расположении рёбер с теми же степенями узлов. Больше — лучше.

SW, CH, AVI, AVU, ANUI и MQ считаются кодом библиотеки Pattern (С. Шалилех, репозиторий `Sorooshi/Pattern`, зафиксированный коммит), S_Dbw — пакетом `s-dbw`.

5.3. Есть ли кластерная структура

Небольшой силуэт (около 0,1) бывает и тогда, когда однородное облако точек просто разрезано на части. Проверка — нулевая модель: каждый столбец матрицы признаков независимо перемешивается по МО, так что распределения признаков сохраняются, а связи между ними разрушаются. На 10 таких перестановках k-средних при K от 2 до 8 даёт силуэт не выше 0,041, а на реальных признаках — от

0,231 (K = 2) до 0,099 (K = 8), в 2,9–5,6 раза выше максимума нулевой модели; CH — 572…234 против не более 61,9 (`outputs/cluster/null_structure.csv`). Типы выделяются на фоне случайного.

5.4. Как выбрать число типов

Индексы по отдельности тянут в разные стороны (это показывают и сравнительные исследования индексов [11]), поэтому нужно правило, объединяющее их, и проверка, какое правило чаще находит верное K. Проверка — на синтетических атрибутированных сетях с известным числом групп; этот подход предложен в докладе С. Шалилеха и Е. Антонова на AI Journey 2025 [12]. Сети строились генератором из репозитория KEFRiN без изменений (`outputs/cluster/synthetic_*.csv`):

- **сильные признаки** — 60 сетей: 400 узлов; 28 признаков и 2 шумовых; истинное K = 2, 3, 4, 5, 7; параметр смешения групп по признакам pr_v = 0,7 и 0,9; сеть «лёгкая» (вероятность ребра внутри группы 0,08, между группами 0,01) и «трудная» (0,05 и 0,02); 3 повтора;
- **слабые признаки** — 24 сети: pr_v = 0,1 и 0,2, истинное K = 3 и 5, остальное так же.

На каждой сети KEFRiN (ξ = 2, как в работе) запускался при K = 2…8 и 10. Сравнивались индексы и четыре правила агрегирования: голосование SW, CH и MQ по первым местам; метод Борда — сумма рангов K по всем семи индексам; Борда по SW, CH и MQ; **Борда по блокам** — признаковый блок (средний ранг K по SW и CH) и сетевой блок (ранг по MQ) с равным весом.

Таблица 2. Доля сетей, где индекс или правило указали истинное K.

	SW	CH	MQ	S_Dbw	AVI	AVU	ANUI	Голосование	Борда, все	Борда, SW CH MQ	Борда по блокам
Сильные признаки	0,67	0,67	0,70	0,00	0,20	0,03	0,45	0,67	0,63	0,67	0,68
Слабые признаки	0,25	0,12	0,46	0,04	0,00	0,00	0,25	0,21	0,46	0,33	0,42

S_Dbw, AVI и AVU непригодны для выбора K: они монотонны по числу групп и указывают на край перебора. При сильных признаках правила почти не различаются; при истинном K = 2 и 3 SW, CH, MQ и голосование находят его во всех сетях. При слабых признаках голосование ошибается чаще остальных (0,21), потому что два из трёх голосов — признаковые индексы, а признаки неинформативны. Из одиночных индексов точнее всех MQ (0,70 и 0,46). Выбрана **Борда по блокам**: она почти так же точна (0,68 и 0,42), а признаковый и сетевой взгляды в ней весят поровну. Если у двух K одинаковая сумма рангов, выбирается K с лучшим рангом MQ — самого точного одиночного индекса. На синтетических сетях сумма рангов совпала у двух K в 3 случаях из 84, и любой способ разрешить ничью давал ту же точность.

5.5. Вес сети ξ

KEFRiN запускался при ξ = 0, 1, 2, 5, 10, 20, 50 и K = 4 и 8 на правиле «слияние» (`outputs/cluster/kefrin_xi.csv`). При K = 8 и ξ = 2 модульность растёт с 0,375 (ξ = 0, то есть k-средних) до 0,408, изолированность AVI — с 0,51 до 0,57, а силуэт SW остаётся на уровне k-средних (0,102 против 0,095). При ξ ≥ 5 силуэт падает (0,084 при ξ = 5, 0,015 при ξ = 10), при ξ = 20 и 50 становится отрицательным: кластеры определяет одна сеть. Выбран ξ = 2.

5.6. Сравнение методов

На синтетике — насколько метод восстанавливает истинное разбиение при известном K. Мера — скорректированный индекс Рэнда (adjusted Rand index, ARI [13]): 1 — полное совпадение, 0 — совпадение на уровне случайного.

Таблица 3. ARI с истинным разбиением, среднее по сетям (`outputs/cluster/synthetic_methods_ari*.csv`).

Метод	Сильные признаки, лёгкая сеть	Сильные, трудная	Слабые, лёгкая	Слабые, трудная	Среднее
KEFRiN, ξ = 2	0,93	0,91	0,62	0,38	0,71
k-средних (только признаки)	1,00	1,00	0,45	0,45	0,73
Leiden (только сеть)	0,88	0,13	0,95	0,04	0,50
Спектральная (только сеть)	0,87	0,19	0,94	0,10	0,53

Методы только по сети выигрывают при чистых связях и проваливаются при зашумлённых. k-средних выигрывает при сильных признаках и проигрывает KEFRiN, когда признаки слабы, а сеть информативна. KEFRiN ни в одном условии не опускается ниже 0,38 и в среднем близок к k-средних. Для реальной сети, качество связей в которой заранее неизвестно, выбран метод без провалов.

На реальных данных — шесть методов при итоговом K = 5 на правиле «слияние», по 10 запусков с разными начальными состояниями; у KEFRiN и k-средних одинаковое число перезапусков (10).

Таблица 4. Индексы, среднее ± стандартное отклонение по 10 запускам (`outputs/cluster/methods_seeds_summary.csv`).

Метод	SW ↑	CH ↑	S_Dbw ↓	AVI ↑	AVU ↓	ANUI ↑	MQ ↑
KEFRiN, ξ = 2	0,116 ± 0,000	318 ± 0	0,834 ± 0,000	0,690 ± 0,002	0,521 ± 0,002	0,507 ± 0,001	0,472 ± 0,002
k-средних	0,117 ± 0,000	319 ± 0	0,834 ± 0,000	0,643 ± 0,003	0,521 ± 0,001	0,481 ± 0,002	0,428 ± 0,002
Смесь гауссовых распределений	0,104 ± 0,014	245 ± 1	0,883 ± 0,015	0,593 ± 0,004	0,569 ± 0,009	0,443 ± 0,004	0,379 ± 0,007
Уорд	0,107 ± 0,000	283 ± 0	0,846 ± 0,000	0,604 ± 0,000	0,544 ± 0,000	0,455 ± 0,000	0,390 ± 0,000
Leiden	0,016 ± 0,014	146 ± 17	0,874 ± 0,013	0,973 ± 0,002	0,484 ± 0,022	0,661 ± 0,011	0,733 ± 0,016
Спектральная	0,047 ± 0,000	148 ± 0	0,876 ± 0,000	0,975 ± 0,000	0,428 ± 0,000	0,688 ± 0,000	0,628 ± 0,000

KEFRiN совпадает с k-средних по признаковым индексам (SW 0,116 против 0,117; CH 318 против 319; S_Dbw 0,834 у обоих) и превосходит его по сетевым (MQ 0,472 против 0,428, AVI 0,690 против 0,643). Методы только по сети дают лучшие сетевые индексы при силуэте около нуля: их кластеры связны, но внутри неоднородны по экономике. Смесь гауссовых распределений и метод Уорда уступают KEFRiN по всем семи индексам.

6. Типология

6.1. Число типов

KEFRiN (ξ = 2, правило «слияние») запускался при K от 2 до 8 на всех 2 068 МО; K выбрано Бордой по блокам.

Таблица 5. Выбор числа типов (`outputs/typology/icvi_macro.csv`).

K	SW	CH	MQ	Ранг признакового блока	Ранг сетевого блока	Сумма
2	0,233	572	0,369	1	7	8
3	0,225	437	0,454	2	3	5
4	0,150	364	0,430	3	5	8
5	**0,117**	**318**	**0,470**	**4**	**1**	**5**
6	0,094	275	0,435	6	4	10
7	0,097	245	0,468	6	2	8
8	0,102	233	0,408	6	6	12

По отдельности SW и CH указывают на наименьшее K, модульность — на K = 5. Сумма рангов двух блоков одинакова у K = 3 и K = 5; по правилу из раздела 5.4 выбрано K = 5 с лучшим рангом MQ. Индексы итогового разбиения: SW 0,117; CH 318; S_Dbw 0,835; AVI 0,688; AVU 0,522; ANUI 0,506; MQ 0,470.

Устойчивость. На 20 случайных подвыборках по 80% МО KEFRiN при K = 5 воспроизводит итоговые типы: ARI в медиане 0,937, от 0,45 до 0,97 (`outputs/typology/stability.csv`).

6.2. Типы

Типы пронумерованы по возрастанию медианных трат жителя. Название дано по медианам признаков (`outputs/interpret/profile_median.csv`) и по регионам, где МО типа больше всего.

Таблица 6. Типы и их показатели: медиана по МО типа; для долей занятых в обработке и добыче — среднее, потому что у большинства МО таких занятых нет и медиана равна нулю.

	1. Убывающие районы Центра и Поволжья	2. Сельские районы Сибири и Урала	3. Города и промышленные центры	4. Ресурсные территории	5. Мегаполисы и их пригороды	Россия
Число МО	590	563	469	158	288	2 068
Траты жителя в месяц, руб.	22 838	23 153	32 000	41 016	50 051	26 567
Доля продовольствия	47,3%	45,8%	40,9%	42,3%	32,0%	44,1%
Доля общепита	1,5%	2,0%	4,2%	3,6%	7,8%	2,6%
Доля маркетплейсов	18,9%	15,8%	15,5%	11,4%	13,1%	16,0%
Зарплата, руб.	49 702	54 075	70 579	124 733	125 672	61 572
Доля 65+	19,9%	15,5%	16,3%	10,5%	18,6%	17,1%
Доля 0–15 лет	15,6%	20,6%	17,9%	21,9%	16,4%	18,0%
Рождаемость на 1 000 жителей	6,7	9,2	7,7	9,3	7,4	8,0
Смертность на 1 000 жителей	17,7	15,2	13,9	12,4	8,5	15,1
Миграция на 1 000 жителей	−6,1	−9,8	0,0	−8,1	+15,3	−4,3
Доля горожан	43%	0%	87%	63%	100%	56%
Доступность рынков	345	269	328	150	534	323
Занятость в обработке, среднее	4,6%	3,2%	24,1%	3,1%	12,1%	9,6%
Занятость в добыче, среднее	0,3%	1,1%	2,0%	18,3%	0,3%	2,3%
Занятость в госуправлении	14,4%	13,7%	8,4%	7,9%	3,0%	11,3%
Инвестиции на жителя, тыс. руб.	26	25	61	322	116	40

1. **Убывающие районы Центра и Поволжья** — больше всего в Кировской, Нижегородской, Саратовской, Тверской и Рязанской областях. Смертность самая высокая (17,7 на 1 000 жителей) при самой низкой рождаемости (6,7), население убывает на 1,4% в год. Самые низкие траты жителя и наибольшая доля маркетплейсов в них. Доля пожилых (19,9%) выше средней по стране, но почти такая же, как в мегаполисах (18,6%).
2. **Сельские районы Сибири и Урала** — Алтайский и Красноярский края, Башкортостан, Омская и Иркутская области. У большинства МО нет городского населения. Много детей, самый большой отток жителей, наибольшая доля занятых в сельском хозяйстве.

3. **Города и промышленные центры** — 43 из 67 административных центров субъектов, вошедших в типологию, и промышленные города Свердловской, Кемеровской, Челябинской областей и Подмосковья. Обработка даёт в среднем четверть рабочих мест, высокие розничный оборот и платные услуги.
4. **Ресурсные территории** — Якутия, Югра, Сахалин, Ямал, Камчатка. Почти каждый пятый занятый — в добыче, инвестиции на жителя в 8 раз выше медианы страны, самая низкая доступность рынков, траты — наименьшая доля зарплаты.
5. **Мегаполисы и их пригороды** — 234 района Москвы и Санкт-Петербурга, 16 административных центров субъектов (Казань, Новосибирск, Екатеринбург, Нижний Новгород, Самара, Пермь, Уфа и другие) и пригороды крупных городов (Лаишевский и Верхнеуслонский районы у Казани, Новосибирский и Тюменский районы, 21 МО Московской области). Самые высокие траты, наибольшие доли общепита и транспорта, наименьшая — продовольствия, самый большой приток жителей.

Типы выстраиваются по градиенту «центр — периферия», описанному для регионов России Н. В. Зубаревич [14]: мегаполисы с притоком жителей, затем промышленные города, затем убывающие и сельские районы. Убыль населения сельских районов Центральной России — многолетний процесс, подробно описанный географами [15]; в типологии он виден как тип с самой высокой смертностью и самой низкой рождаемостью.

6.3. Описание типов интервальными узорными структурами

Узорная структура (pattern structure; Ganter, Kuznetsov, 2001 [16]) обобщает анализ формальных понятий на числовые признаки без перевода их в двоичные. В интервальной узорной структуре (Kaytoue, Kuznetsov и др., 2011 [17]) описание множества МО A — вектор интервалов [min, max] значений признаков по A; это замыкание A в структуре. Объём описания — все МО страны, чьи значения попадают во все интервалы.

Для каждого типа описание строится так:

1. признаки — четыре, сильнее всего отличающие тип от страны (по медиане стандартизованных значений); остаточная категория «прочее» и признаки с покрытием МО ниже 80% не используются;
2. A — ядро типа, половина его МО, ближайших к центру типа;
3. описание — интервалы признаков по ядру.

Качество описания проверяется на данных, по которым оно не строилось: МО случайно делятся пополам, описание строится по ядру типа в одной половине, а точность (доля объёма в типе) и полнота (доля типа в объёме) считаются на другой. Устойчивость — средний индекс Жаккара объёма описания по 20 подвыборкам 80% МО типа и объёма по всему типу (1 — объёмы совпадают).

Таблица 7. Описания типов (`outputs/interpret/interval_patterns.json`).

Тип	Описание	Точность	Полнота	Устойчивость
1. Убывающие районы Центра и Поволжья	доля общепита 0,4–2,8%; зарплата 38 636–70 039 руб.; доля маркетплейсов 15,8–21,8%; доля 65+ 16,0–23,1%	0,73	0,59	0,95
2. Сельские районы Сибири и Урала	доля горожан 0–51%; занятость в обработке 0–11,3%; траты 18 505–28 120 руб.; доля общепита 0,9–3,5%	0,59	0,63	0,98
3. Города и промышленные центры	занятость в обработке 5,5–42,0%; доля горожан 23–100%; население 19 938–288 947; волатильность трат 0,049–0,083	0,59	0,51	0,94
4. Ресурсные территории	доступность рынков 114–244; зарплата 94 966–203 877 руб.; инвестиции 80 тыс. — 1,77 млн руб. на жителя; рабочих мест на жителя 0,22–0,81	0,69	0,29	0,93
5. Мегаполисы и их пригороды	доля общепита 6,0–9,2%; траты 43 347–57 287 руб.; доля продовольствия 28,7–34,6%; доступность рынков 371–650	1,00	0,52	0,94

Описание по ядру покрывает типичных представителей типа, поэтому точность выше полноты. Больше всего пересекаются объёмы описаний двух самых близких типов — убывающих и сельских районов: общих МО у них 199 (`interval_patterns_overlap.csv`).

6.4. Пороговые правила

Дерево решений глубины 3 (не менее 20 МО в листе), обученное различать типы по показателям в исходных единицах, правильно относит 79% МО на обучающих данных и 73% при пятикратной перекрёстной проверке (`outputs/interpret/tree_rules.txt`). Первое разбиение — траты жителя 28 082 руб. в месяц: ниже порога лежат убывающие и сельские районы, выше — города, ресурсные территории и мегаполисы. Убывающие и сельские районы дальше разделяет доля детей (17,8%). Выше порога, если доля продовольствия не больше 35,5%, мегаполисы отделяет от городов зарплата 81 130 руб.; если больше — ресурсные территории отделяет от городов волатильность трат 0,073.

6.5. Сверка с категориями МО

Лаборатория СберИндекса в итогах потребления 2025 года разделяла МО на сельские территории, пригороды агломераций, центры регионов, добывающие территории и наукограды. Для сверки

категории определены по справочнику и Росстату (`outputs/interpret/lab_categories_by_type.csv`):

- 81% типа «мегаполисы и их пригороды» — внутригородские территории Москвы и Санкт-Петербурга;
- 48% ресурсных территорий — МО с долей занятых в добыче не меньше 15% (эта доля — один из признаков, поэтому совпадение отчасти заложено построением);
- 43 из 67 административных центров субъектов — в типе «города и промышленные центры», 16 — в мегаполисах, 7 — в ресурсных территориях;
- сельские территории (доля горожан меньше 30%) — 64% сельских районов Сибири и Урала и 34% убывающих районов, в городах и мегаполисах — 9% и 3%.

7. Динамика

Типология построена по окну январь — декабрь 2024 года; центр типа — средние признаков его МО в этом окне. В каждом из 12 окон признаки стандартизуются внутри окна: общий для страны сдвиг (например, рост доли маркетплейсов, который шёл во всех типах почти одинаково) вычитается, и остаётся положение МО относительно страны. МО относится к типу с ближайшим центром. Это же правило применяется и к опорному окну; на нём оно совпадает с типами KEFRiN у 98% МО (расходятся МО, которых в тип отнесла сеть).

Таблица 8. Переходы между типами: строка — окно с концом в январе 2024 года, столбец — в декабре 2024 года (`outputs/dynamics/transitions_first_last.csv`).

из \ в	1	2	3	4	5
1. Убывающие районы	563	6	9	0	0
2. Сельские районы	26	512	7	1	0
3. Города и промышленные центры	3	11	452	3	12
4. Ресурсные территории	0	1	0	151	1
5. Мегаполисы и пригороды	0	0	0	0	278

От окна к окну тип сохраняют 99,2% МО. За год тип сменили 80 МО (3,9%); самые частые переходы — из сельских районов в убывающие (26) и из городов в мегаполисы (12).

Флаг расхождения ставится МО, которое сменило тип за год, или у которого расстояние до центра своего типа растёт быстрее, чем у 95% МО (наклон линейного тренда расстояния по 12 окнам). Флаг получили 178 МО.

8. Продукт

Для каждого из 2 068 МО по окну 2024 года.

- **Сопоставимые МО** — 15 ближайших по евклидову расстоянию в пространстве 30 стандартизованных признаков. Отдельно — до 5 ближайших из тех, до которых не больше 300 км по дорогам.
- **Потенциал** — место МО среди 16 (МО и 15 сопоставимых) по шести показателям: траты жителя, номинальный рост трат 2024 к 2023 году, доли общепита и маркетплейсов, траты к зарплате, зарплата. Для долей большее значение не лучше и не хуже: место показывает положение, а не оценку.

- **Опыт** — три сопоставимых МО с наибольшим номинальным ростом трат за год и три признака, по которым каждое из них сильнее всего отличается от выбранного МО (разность стандартизованных значений).
- **Расхождение** — флаг и траектория типа по 12 окнам.

Проверка главного тезиса. Для каждого МО вне Москвы и Санкт-Петербурга (1 825 МО) вывод «выше или ниже медианы» получен дважды: среди МО своего региона и среди 16 (МО и 15 сопоставимых). Вывод меняется у 39,0% МО по тратам жителя, у 24,8% по росту трат, у 22,4% по отношению трат к зарплате и у 28,4% по доле маркетплейсов (`outputs/dataset/thesis_check.csv`). У типичного МО из своего региона только 3 из 15 сопоставимых. Пример — Чебоксары: траты жителя на 77% выше медианы Чувашии, но среди 16 сопоставимых (Пермь, Ижевск, Киров, Набережные Челны, Омск и др.) — 15-е место. Похожая картина у других центров регионов: Оренбург — на 15-м месте из 16, Астрахань и Ульяновск — на 14-м, Саратов — на 13-м.

Пример карточки — Комсомольск-на-Амуре (город и промышленный центр). Сопоставимые МО: Братск, Артёмовский, Ачинск, Новокузнецкий, Ухта, Находкинский и ещё 9 промышленных городов Сибири, Урала, Севера и Дальнего Востока. По тратам жителя (43 257 руб. в месяц) он первый из 16.

Траты жителей на рубль местных зарплат. Отношение средних трат жителя в месяц к фонду оплаты труда организаций МО без малого предпринимательства в расчёте на жителя в месяц (Росстат, 2024). Медиана по 1 817 МО — 2,57. По типам: убывающие районы 2,97, сельские 2,92, города 2,11, мегаполисы 2,03, ресурсные территории 0,87. Фонд оплаты труда на жителя равен средней зарплате, умноженной на число рабочих мест на жителя, поэтому отношение почти целиком определяется тем, как мало в МО рабочих мест в средних и крупных организациях (коэффициент Спирмена с числом рабочих мест на жителя −0,95). Больше единицы — жители тратят деньги, которые получают не как зарплату в местных организациях: пенсии и выплаты, работа в другом МО, неформальные доходы. Меньше единицы — начисленное здесь тратится в другом месте, как при вахтовой работе. Малый бизнес этот разрыв не объясняет (раздел 9.2).

Продукт опубликован как датасет `outputs/dataset/mo_peers.csv` и JSON-карточка на каждый МО `outputs/dataset/api/<territory_id>.json`. Ключ — `territory_id` справочника СберИндекса, лицензия — CC BY-SA 4.0 с указанием источника «СберИндекс». Датасет пересчитывается одной командой при выходе нового месяца данных.

9. Внешние проверки

Данные этого раздела в построении типов и сети не участвуют.

9.1. Индекс мобильности СберИндекса

Индекс мобильности — медиана по жителям МО среднего расстояния от центра их покупок до точки каждой покупки, км. Он опубликован для 297 МО Северо-Западного федерального округа. 278 из них сопоставлены с типологией по полному названию МО внутри регионов округа (`outputs/interpret/mobility_by_type.csv`).

Таблица 9. Медиана индекса мобильности по типам, 2024 год.

Тип	Число МО	Мобильность, км
1. Убывающие районы Центра и Поволжья	81	0,51
2. Сельские районы Сибири и Урала	23	0,67
3. Города и промышленные центры	63	1,10
4. Ресурсные территории	7	1,65
5. Мегаполисы и их пригороды	104	4,84

Типы различаются по мобильности: тест Краскела — Уоллиса [18] $H = 182{,}5$, $p \approx 2 \cdot 10^{-38}$; тип объясняет 65% дисперсии рангов мобильности ($\eta^2 = 0{,}65$). Без 98 районов Санкт-Петербурга различие остаётся значимым, но слабее: $\eta^2 = 0{,}36$, $p \approx 1 \cdot 10^{-13}$. Одна доля горожан объясняет 45% дисперсии рангов (квадрат коэффициента Спирмена, 278 МО) — меньше, чем тип.

9.2. Малый и средний бизнес

Источник — реестр субъектов малого и среднего предпринимательства ФНС за 2016–2024 годы, объединённый и обработанный Центром научной информации РЦНИ (data.rcsi.science, набор 205, CC BY-SA 4.0 [19]). Для каждого субъекта в нём есть координаты населённого пункта, а для юридических лиц — среднесписочная численность работников. Субъект относится к МО по координатам: точка попадает в границы МО. Так обходятся смены кодов ОКТМО при преобразовании районов в округа (по коду совпадало бы 72% МО). Итог за 2023 год есть у 89% МО типологии (`data/processed/sme.parquet`).

Занятых в малом и среднем бизнесе на жителя в мегаполисах 0,11, в городах 0,055, в убывающих и сельских районах 0,035 и 0,024. Траты жителя выше там, где больше занятых в малом бизнесе и индивидуальных предпринимателей: коэффициент Спирмена 0,38 и 0,42 по 1 827 МО, внутри типов — 0,20 и 0,39 в медиане (`outputs/interpret/sme_test.csv`). Траты СберИндекса согласуются с независимым реестром предпринимательства.

Отношение трат к зарплатам в местных организациях (раздел 8) с малым бизнесом связано отрицательно: −0,22 по всем МО, −0,09 внутри типов. Там, где траты сильнее всего превышают местные зарплаты, малого бизнеса меньше всего, и разрыв он не объясняет.

9.3. Ночная освещённость

Источник — годовые композиты VIIRS Nighttime Lights V2 [20] (Earth Observation Group, Colorado School of Mines) в пересчёте OpenGeoHub (Zenodo, запись 17294744, CC BY 4.0): средняя яркость за 2023 и 2024 годы, пиксель 500 м. Для МО считается средняя яркость пикселя в его границах и суммарный свет — средняя яркость, умноженная на площадь МО.

Свет на жителя почти не связан с тратами жителя: коэффициент Спирмена 0,05 по 1 969 МО, внутри типов — от −0,16 до 0,30 (`outputs/interpret/nightlights_test.csv`). Больше всего света на жителя в ресурсных территориях (0,056 против 0,009–0,022 у остальных типов): его дают промышленные площадки и факелы попутного газа, а не потребление. Изменение яркости за год не связано ни с ростом трат (−0,08), ни с флагом расхождения ($p = 0{,}13$). Связь освещённости с экономической активностью установлена для стран и крупных регионов [21]. На уровне МО и на горизонте одного года ночная освещённость отражает размещение промышленности и плотность застройки; для проверки трат она не подходит.

9.4. Моногорода и акции градообразующих компаний

Моногород — муниципалитет, где значительная часть жителей работает на одном предприятии или в одной компании. Список моногородов с категорией, которую им присвоил Фонд развития моногородов («сложное положение», «риск ухудшения», «стабильное»), и названием градообразующего предприятия взят из статьи Википедии «Список моногородов России» (зафиксирована версия 154521434). Из 335 моногородов списка с МО СберИндекса по названию и региону сопоставлено 213, в типологию входят 179 (`outputs/interpret/monotowns.csv`).

Типология выделяет моногорода без подсказки: 116 из 178 моногородов с категорией Фонда (65%) попадают в тип «Города и промышленные центры», тогда как среди всех МО этот тип составляет 23% (469 из 2 068; `outputs/interpret/monotowns_by_type.csv`). Ещё 44 моногорода — в типе «Убывающие районы Центра и Поволжья».

Категория Фонда с тратами 2024 года не связана. Медианный рост трат — 15–16% во всех трёх категориях (тест Краскела — Уоллиса, $p = 0{,}73$), место по росту трат среди 15 сопоставимых МО тоже не различается ($p = 0{,}68$), флаг расхождения встречается одинаково часто (хи-квадрат, $p = 0{,}22$; `outputs/interpret/monotowns_test.csv`). Категории присвоены по данным прошлых лет и описывают риск для занятости, который в тратах 2024 года не проявился.

Для 24 моногородов градообразующее предприятие принадлежит компании, акции которой торгуются на Московской бирже (16 компаний). Изменение цены акции за 2024 год (цены закрытия первого и последнего торгового дня, с поправкой на дробление акций) — от −67% до +6%. С ростом трат жителей в моногороде оно не связано: коэффициент Спирмена −0,35, $p = 0{,}09$ (`data/raw/moex_2024.csv`). Цена акции отражает прибыль всей компании и цены на её продукцию на мировом рынке, а траты жителей — прежде всего зарплаты, которые компания меняет с запаздыванием. Градообразующее предприятие влияет на траты жителей через местную занятость: в США каждое новое рабочее место в обрабатывающей промышленности города создаёт в среднем 1,6 рабочего места в местной торговле и услугах [22].

9.5. Новости

Тексты новостей используются в экономике как источник данных о событиях, которых нет в статистике [23]. Проверяется, отражается ли флаг расхождения в новостях. Сравниваются две группы: 178 МО с флагом и 178 МО без флага того же типа (контроль). Для каждого МО из поиска Google News взяты заголовки 2024 года, по запросу на каждый месяц (название МО и региона). Остаются заголовки, где названо само МО, а не одноимённый регион. Получено 2 842 заголовка по 281 МО (`outputs/news/news.parquet`).

Заголовки размечали две открытые языковые модели, запущенные на Kaggle (две видеокарты T4) в Ollama: Qwen3.5-35B-A3B (лицензия Apache 2.0, веса в 4 битах) и GigaChat 3.1 10B-A1.8B (MIT, 8 бит). Для каждого заголовка модель выбирает категорию события из девяти и отвечает, затрагивает ли событие экономику МО: занятость, доходы жителей, торговлю, производство или инвестиции. Ответ ограничен JSON-схемой (`kaggle/news_kernel.py`).

Языковые модели размечают тексты не хуже разметчиков-людей на ряде задач [24], но качество зависит от модели и задачи, поэтому модель выбрана по ручной разметке 120 заголовков (`kaggle/gold_labels.json`; экономическими признаны 15). Согласие с ручной разметкой измеряется каппой Коэна [25]: это доля совпадений сверх той, что получилась бы при случайных ответах с теми же частотами. Каппа 1 означает полное совпадение, 0 — совпадение на уровне случайного. У Qwen3.5 каппа 0,68 при 93% совпадений, у GigaChat — 0,54 при 90% (`outputs/news/labeler_agreement.csv`). Дальше используется разметка Qwen3.5.

Экономические события нашлись у 24% МО с флагом и у 33% МО контроля (точный тест Фишера, p = 0,08; `outputs/news/divergence_vs_control.csv`). О МО с флагом пишут реже: в среднем 6,3 заголовка за год против 9,7 (медиана 2 против 3), а чем больше заголовков, тем вероятнее среди них экономическое событие. С поправкой на число заголовков (логистическая регрессия наличия экономического события на группу и логарифм числа заголовков) различие групп не значимо: p = 0,19 (`outputs/news/divergence_adjusted.csv`). В федеральной и региональной повестке, которую собирает Google News, флаг расхождения не отражается. У типичного МО 2–3 заголовка за год, поэтому такая проверка заметила бы только сильную связь.

10. Обсуждение

Для 39% муниципалитетов сравнение с экономически сопоставимыми даёт другой вывод о тратах жителей, чем сравнение со своим регионом. Региональный центр, заметно опережающий свой регион, среди сопоставимых городов может оказаться в хвосте. Продукт даёт такое сравнение для любого МО вместе с ориентирами, у кого учиться. Пять типов, на которых он построен, экономически осмысленны: они совпадают с категориями лаборатории СберИндекса (мегаполисы, центры регионов, добывающие и сельские территории), подтверждаются независимым индексом мобильности, реестром малого бизнеса и списком моногородов и описываются короткими интервальными описаниями с проверкой на отложенных данных.

Методический результат — выбор числа кластеров на атрибутированной сети. На синтетических сетях с известным ответом S_Dbw, AVI и AVU непригодны для выбора K, голосование индексов по первым местам ошибается при слабых признаках, а метод Борда по двум равновесным блокам (признаки и сеть) точнее остальных правил агрегирования. KEFRiN с весом сети ξ = 2 не проваливается ни при слабых признаках, ни при зашумлённой сети; на реальных данных он совпадает с k-средних по признаковым индексам и превосходит его по сетевым.

Развивать работу стоит в четырёх направлениях. Первое — более длинные ряды трат: 24 месяца не позволяют надёжно оценить сезонность и опережение одних МО другими. Второе — матрица потоков трат между МО (где тратят жители): она дала бы правило ребра по реальным экономическим связям и ответ на вопрос, откуда берутся траты сверх местных зарплат. Третье — местные источники новостей: сайты администраций и районные газеты пишут о своём МО чаще, чем федеральные издания. Четвёртое — проверка продукта на данных 2025 года: предсказывают ли сопоставимые МО рост трат лучше, чем свой регион.

Ограничения. Оценка трат СберИндекса основана на данных одного банка; его доля на рынке различается по регионам, поэтому межрегиональные сравнения уровня трат надёжнее внутри типа. Рост трат номинальный; различия региональной инфляции в 2024 году не учтены. Часть показателей Росстата отсутствует у части МО и заполняется по похожим МО. Для районов Москвы и Санкт-Петербурга сопоставимые МО находятся в основном в том же городе.

11. Воспроизводимость

```
uv sync                        # или: pip install -r requirements.txt
uv run mopeers all
```

Все гиперпараметры — в `configs/base.yaml`, названия и описания типов — в `configs/types.yaml`. Исходные данные скачиваются из официальных источников, пакет Data Sense проверяется по SHA-256; при недоступности источника используется снимок данных из релиза репозитория. Сторонний код

(KEFRiN, генератор синтетических сетей, метрики Pattern) скачивается с зафиксированных коммитов репозиториев авторов. Случайные запуски фиксируются `seed: 0`. Полный прогон после скачивания данных занимает 25–35 минут на ноутбуке без GPU; прогон с нуля в чистой копии репозитория воспроизводит побайтно все таблицы и наборы данных в `outputs/` и лендинг. Контрольные суммы SHA-256 всех результатов — в `outputs/SHA256SUMS` (проверка: `sha256sum -c outputs/SHA256SUMS`); тесты в `tests/` проверяют правила конвейера на примерах с известным ответом и целостность опубликованного продукта (`uv run pytest`). Внешние проверки запускаются отдельно (`mopeers.sme`, `mopeers.nightlights`, `mopeers.monotowns`, `mopeers.news`); агрегаты реестра МСП и ночной освещённости по МО опубликованы в `data/processed/`.

Литература

1. Chetty R., Friedman J. N., Stepner M., Opportunity Insights Team. The economic impacts of COVID-19: evidence from a new public database built using private sector data // The Quarterly Journal of Economics. 2024. Vol. 139, No. 2. P. 829–889.
2. Troyanskaya O., Cantor M., Sherlock G., Brown P., Hastie T., Tibshirani R., Botstein D., Altman R. B. Missing value estimation methods for DNA microarrays // Bioinformatics. 2001. Vol. 17, No. 6. P. 520–525.
3. Traag V. A., Waltman L., van Eck N. J. From Louvain to Leiden: guaranteeing well-connected communities // Scientific Reports. 2019. Vol. 9. 5233.
4. Sakoe H., Chiba S. Dynamic programming algorithm optimization for spoken word recognition // IEEE Transactions on Acoustics, Speech, and Signal Processing. 1978. Vol. 26, No. 1. P. 43–49.
5. Shalileh S., Mirkin B. Community partitioning over feature-rich networks using an extended k-means method // Entropy. 2022. Vol. 24, No. 5. P. 626.
6. Arthur D., Vassilvitskii S. k-means++: the advantages of careful seeding // Proceedings of the 18th Annual ACM-SIAM Symposium on Discrete Algorithms. 2007. P. 1027–1035.
7. Rousseeuw P. J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis // Journal of Computational and Applied Mathematics. 1987. Vol. 20. P. 53–65.
8. Caliński T., Harabasz J. A dendrite method for cluster analysis // Communications in Statistics. 1974. Vol. 3, No. 1. P. 1–27.
9. Halkidi M., Vazirgiannis M. Clustering validity assessment: finding the optimal partitioning of a data set // Proceedings of IEEE ICDM. 2001. P. 187–194.
10. Newman M. E. J. Modularity and community structure in networks // PNAS. 2006. Vol. 103, No. 23. P. 8577–8582.
11. Arbelaitz O., Gurrutxaga I., Muguerza J., Pérez J. M., Perona I. An extensive comparative study of cluster validity indices // Pattern Recognition. 2013. Vol. 46, No. 1. P. 243–256.
12. Шалилех С., Антонов Е. Поведение индексов качества кластеризации атрибутированных сетей на синтетических данных с контролируемыми параметрами. Доклад на конференции AI Journey 2025. СберИндекс, 2025.
13. Hubert L., Arabie P. Comparing partitions // Journal of Classification. 1985. Vol. 2. P. 193–218.
14. Зубаревич Н. В. Регионы России: неравенство, кризис, модернизация. М.: Независимый институт социальной политики, 2010.
15. Нефёдова Т. Г. Десять актуальных вопросов о сельской России: ответы географа. М.: ЛЕНАНД, 2013.

16. Ganter B., Kuznetsov S. O. Pattern structures and their projections // Conceptual Structures: Broadening the Base (ICCS 2001). LNCS 2120. Springer, 2001. P. 129–142.
17. Kaytoue M., Kuznetsov S. O., Napoli A., Duplessis S. Mining gene expression data with pattern structures in formal concept analysis // Information Sciences. 2011. Vol. 181, No. 10. P. 1989–2001.
18. Kruskal W. H., Wallis W. A. Use of ranks in one-criterion variance analysis // Journal of the American Statistical Association. 1952. Vol. 47, No. 260. P. 583–621.
19. Реестр субъектов малого и среднего предпринимательства за 2016–2024 гг. с доходами. ФНС России; обработка — Центр научной информации РЦНИ. data.rcsi.science, набор 205.
20. Elvidge C. D., Zhizhin M., Ghosh T., Hsu F.-C., Taneja J. Annual time series of global VIIRS nighttime lights derived from monthly averages: 2012 to 2019 // Remote Sensing. 2021. Vol. 13, No. 5. 922.
21. Henderson J. V., Storeygard A., Weil D. N. Measuring economic growth from outer space // American Economic Review. 2012. Vol. 102, No. 2. P. 994–1028.
22. Moretti E. Local multipliers // American Economic Review. 2010. Vol. 100, No. 2. P. 373–377.
23. Gentzkow M., Kelly B., Taddy M. Text as data // Journal of Economic Literature. 2019. Vol. 57, No. 3. P. 535–574.
24. Gilardi F., Alizadeh M., Kubli M. ChatGPT outperforms crowd workers for text-annotation tasks // PNAS. 2023. Vol. 120, No. 30. e2305016120.
25. Cohen J. A coefficient of agreement for nominal scales // Educational and Psychological Measurement. 1960. Vol. 20, No. 1. P. 37–46.