Сопоставимые муниципалитеты

Сопоставимые муниципалитеты: типология локальных экономик России на атрибутированной сети

Методологический отчёт. Онлайн-конкурс СберИндекса 2026, направление «Кластеризация».

1. Задача и результат

Сравнение со средним по региону мало говорит о конкретном муниципальном образовании (МО). Полезнее сравнивать МО с экономически сопоставимыми: так можно оценить потенциал, найти применимый опыт и заметить расхождение в развитии. Работа строит такое сравнение для 2 068 МО.

Результат состоит из трёх частей.

1. **Типология.** Пять типов локальной экономики на двух уровнях: сначала два макротипа, затем подтипы внутри каждого. Типы найдены алгоритмом KEFRiN на атрибутированной сети МО (раздел 5).
2. **Динамика.** Для каждого из 12 месяцев 2024 года МО отнесено к ближайшему типу; видно, кто сменил тип и чьё положение смещается (раздел 7).
3. **Продукт.** Для каждого МО — 15 экономически сопоставимых, место МО среди них по ключевым показателям, сопоставимые МО с наибольшим ростом трат и флаг расхождения с типом (раздел 8). Продукт опубликован как датасет с ключом `territory_id` справочника СберИндекса и как интерактивный лендинг.

2. Данные

Траты жителей (СберИндекс). Средние безналичные потребительские расходы жителя МО в месяц, рубли, январь 2023 — декабрь 2024 года. Трата относится к месту жительства покупателя. Пять категорий: продовольствие, общественное питание, здоровье, транспорт, маркетплейсы, и итог «все категории»; разность итога и суммы пяти категорий названа «прочее». В панели 2 190 МО; около 500 МО в отдельные месяцы отсутствуют, потому что оценка СберИндекса для них не проходит порог качества.

Контекст МО.

- Пакет хакатона СберИндекса Data Sense 2025: население по возрасту и полу (2023–2024), миграция (2023), среднемесячная зарплата работников организаций без малого предпринимательства (2023–2024).
- Индекс доступности рынков СберИндекса (2024) и дорожные расстояния между центрами МО из пакета конкурса.
- База данных показателей муниципальных образований Росстата, 14 показателей. Для каждого взят последний год, в котором значения есть не менее чем у 70% МО от года с наибольшим покрытием: доля городского населения, рождаемость, смертность, оборот розничной торговли, платные услуги, инвестиции в основной капитал, жилищный фонд, продукция сельского

хозяйства на жителя, число рабочих мест на жителя, доли занятых в добыче, обработке, государственном управлении, сельском хозяйстве.

Коды показателей Росстата и фильтры разрезов записаны в `configs/base.yaml`. Отраслевая доля занятости при известном итоге и отсутствующем разделе принимается равной нулю: Росстат не публикует раздел без работников или с единичными работниками.

Ключи. МО связываются через `territory_id` справочника СберИндекса; для Росстата — через код ОКТМО из того же справочника.

3. Признаки

Признаки считаются в скользящем окне 12 месяцев. Окно с концом в месяце t охватывает месяцы t−11…t. Концы окон — 12 месяцев 2024 года, поэтому у каждого окна есть рост к тем же месяцам 2023 года. МО входит в окно, если у него есть данные не менее чем за 10 месяцев из 12; в окне, закончившемся в декабре 2024 года, таких МО 2 068.

Всего 30 признаков в трёх группах.

1. **Структура трат** — доля каждой из шести категорий в тратах за окно (6 признаков).
2. **Динамика трат** — логарифм средних трат в месяц; рост трат за последние 3 месяца к тем же месяцам прошлого года; сезонная амплитуда — разность максимальных и минимальных месячных трат, делённая на средние; волатильность — стандартное отклонение месячных приростов логарифма трат (4 признака).
3. **Контекст** — «невидимая экономика» (средние траты жителя в месяц, делённые на официальную зарплату: например, траты 30 тыс. руб. при зарплате 60 тыс. руб. дают 0,5), 19 показателей Росстата и СберИндекса из раздела 2 (20 признаков).

Показатели на жителя с тяжёлыми хвостами (население, зарплата, доступность рынков, оборот, услуги, инвестиции, жильё, рабочие места) логарифмируются. Пропуски заполняются медианой по стране. Все признаки стандартизуются: из значения вычитается среднее по МО и результат делится на стандартное отклонение; значения за пределами ±5 обрезаются.

4. Сеть

Узел сети — МО. Ребро соединяет МО с его k = 10 ближайшими соседями по правилу сходства; сеть делается симметричной (ребро есть, если хотя бы один из двух МО входит в соседи другого). Вес ребра — сходство, приведённое к отрезку [0, 1].

Сравнивались шесть правил сходства двух МО.

Правило	Как считается
Структура трат	косинус угла между векторами отклонений долей шести категорий от средних долей по стране
Корреляция приростов	коэффициент корреляции Пирсона месячных приростов логарифма трат
Лаговая корреляция	максимум корреляции приростов при сдвиге одного ряда относительно другого на 0, 1 или 2 месяца: учитывает, что один МО может опережать другой
DTW	сходство формы рядов трат после динамического выравнивания во времени (dynamic time warping) с окном Сакоэ — Тибы 2 месяца; расстояние d переводится в сходство exp(−d / медиана d)
Дорожная близость	exp(−расстояние по дорогам / 150 км)
Слияние	среднее рангов сходства по структуре трат и по дорожной близости

Чтобы сравнить правила, для каждого считались четыре величины на окне 2024 года.

- **Однородность соседей** — насколько соседи по сети ближе друг к другу по 30 признакам, чем случайная пара МО. Равна 1 − (среднее расстояние между концами рёбер) / (среднее расстояние между случайными парами). 0 означает, что соседи не ближе случайных, 1 — что соседи одинаковы.
- **Модульность разбиения Leiden** — насколько сеть распадается на плотные сообщества.
- **Доля рёбер внутри одного региона** и **медиана длины ребра по дорогам**.

Таблица 1. Сравнение правил ребра (окно январь — декабрь 2024 года, 2 068 МО; `outputs/network/rules_comparison.csv`).

Правило	Однородность соседей	Модульность Leiden	Рёбра внутри региона	Медиана длины ребра, км
Структура трат	0,30	0,80	15%	966
Корреляция приростов	0,19	0,58	16%	1 128
Лаговая корреляция	0,19	0,58	16%	1 130
DTW	0,19	0,62	14%	1 173
Дорожная близость	0,31	0,88	76%	87
Слияние	0,36	0,83	47%	210

Правила, основанные на форме временных рядов (корреляция, лаговая корреляция, DTW), связывают МО, мало похожие по признакам: за 12 месяцев месячные колебания трат у большинства МО определяются общими для страны сезонными и календарными эффектами. Лаговая корреляция совпадает с обычной: опережения одних МО другими на сдвигах до 2 месяцев в данных нет. Структура трат и дорожная близость по отдельности дают однородность около 0,3; их слияние — 0,36. Для типологии выбрано слияние: соседи по нему наиболее похожи по признакам, а связи остаются в пределах досягаемости (медиана 210 км).

5. Кластеризация

5.1. KEFRiN

KEFRiN (Shalileh, Mirkin, 2022) — расширение метода k-средних на атрибутированные сети. Каждый МО описывается двумя векторами: признаками (30 чисел) и строкой матрицы смежности сети (веса рёбер ко всем остальным МО). У каждого кластера два центра: в пространстве признаков и в пространстве строк сети. МО относится к кластеру, для которого минимальна сумма

расстояние по признакам + ξ × расстояние по сети.

Вес ξ задаёт, насколько учитывается сеть: при ξ = 0 KEFRiN совпадает с k-средних по признакам. Использована реализация авторов (репозиторий `Sorooshi/KEFRiN`, зафиксированный коммит), евклидово расстояние, 3 случайных запуска с инициализацией k-means++.

5.2. Индексы качества

Внутренний индекс качества кластеризации (internal cluster validity index, ICVI) оценивает разбиение без эталонной разметки. Использованы семь индексов; первые три считаются по признакам, остальные — по сети.

- **SW** (силуэт, silhouette width). Для МО i: a — среднее расстояние до МО своего кластера, b — до МО ближайшего чужого; силуэт равен (b − a) / max(a, b). Например, a = 2, b = 3 дают 0,33. SW — среднее по всем МО, от −1 до 1, больше — лучше.
- **CH** (индекс Калинского — Харабаша). Отношение разброса центров кластеров вокруг общего центра к разбросу МО вокруг центров своих кластеров, с поправкой на число кластеров и МО. Больше — лучше.
- **S_Dbw**. Сумма среднего разброса внутри кластеров и плотности МО на серединах отрезков между центрами. Меньше — лучше.
- **AVI** (average isolability, средняя изолированность). Для кластера — доля веса его рёбер, которая остаётся внутри кластера; AVI — среднее по кластерам. Больше — лучше.
- **AVU** (average unifiability, средняя объединяемость). Для пары кластеров — вес рёбер между ними, делённый на вес всех внешних рёбер обоих; AVU — усреднение по парам. Меньше — лучше.
- **ANUI** — объединение двух предыдущих: 1 / (AVU + 1 / AVI). Больше — лучше.
- **MQ** (модульность). Доля веса рёбер внутри кластеров минус та доля, которая получилась бы при случайном расположении рёбер с теми же степенями узлов. Больше — лучше.

SW, CH, AVI, AVU, ANUI и MQ считаются кодом библиотеки Pattern (С. Шалилех, репозиторий `Sorooshi/Pattern`, зафиксированный коммит), S_Dbw — пакетом `s-dbw`.

5.3. Каким индексам доверять при выборе числа кластеров

Чтобы выбрать число кластеров K, нужно знать, какие индексы указывают на верное K. Это проверено на синтетических атрибутированных сетях с известным числом групп — по идее доклада С. Шалилеха и Е. Антонова на AI Journey 2025. Сети строились генератором из репозитория KEFRiN без изменений: 400 узлов; 19 признаков и 2 шумовых; истинное K — 5, 7 или 9; параметр смешения групп по признакам pr_v — 0,7 или 0,9; вероятность ребра внутри группы 0,08, между группами 0,01; по два повтора — всего 12 наборов. На каждом наборе KEFRiN запускался при K = 4, 5, …, 10 и 12, и для каждого индекса фиксировалось K с лучшим значением.

Таблица 2. Доля наборов, где индекс указал истинное K (`outputs/cluster/synthetic_k_accuracy.csv`).

SW	CH	MQ	S_Dbw	AVI	AVU	ANUI	средний ранг по всем семи
11 из 12	11 из 12	11 из 12	0 из 12	0 из 12	0 из 12	0 из 12	7 из 12

AVI и ANUI всегда выбирают наименьшее K перебора (4): чем меньше кластеров, тем больше рёбер остаётся внутри них. S_Dbw выбирает K от 10 до 12, AVU — от 6 до 12 без связи с истинным K. Средний ранг по всем индексам ошибается из-за этих монотонных индексов. Отсюда правило, которым выбирается K в работе: **K выбирают голосованием SW, CH и MQ; при равенстве голосов — меньшее K.** S_Dbw, AVI, AVU и ANUI используются для сравнения методов при одинаковом K.

5.4. Вес сети ξ

KEFRiN запускался при ξ = 0, 1, 2, 5, 10, 20, 50 и K = 4 и 8 на правиле «слияние» (`outputs/cluster/kefrin_xi.csv`). При K = 8 и ξ = 2 модульность растёт с 0,37 (ξ = 0, то есть k-средних) до 0,46, изолированность AVI — с 0,51 до 0,65, а силуэт SW остаётся на уровне k-средних (0,102 против 0,100). При ξ ≥ 5 силуэт падает, при ξ = 50 разбиение вырождается (SW < 0). Выбран ξ = 2.

5.5. Сравнение методов

Шесть методов сравнивались на четырёх правилах ребра (слияние, структура трат, дорожная близость, DTW) при K = 2…8, 10 и 12 (`outputs/cluster/icvi_grid.csv`): KEFRiN (признаки и сеть), Leiden с подбором разрешения под заданное K (сеть), спектральная кластеризация (сеть), k-средних, смесь гауссовых распределений и иерархическая кластеризация Уорда (признаки).

Таблица 3. Методы на правиле «слияние» при K = 6 (стрелка — направление «лучше»).

Метод	SW ↑	CH ↑	S_Dbw ↓	AVI ↑	AVU ↓	ANUI ↑	MQ ↑
KEFRiN, ξ = 2 (признаки и сеть)	0,094	241	0,827	0,643	0,543	0,477	0,462
Leiden (сеть)	0,054	139	0,873	0,968	0,438	0,680	0,720
Спектральная (сеть)	0,041	140	0,877	0,969	0,432	0,683	0,715
k-средних (признаки)	0,106	248	0,845	0,600	0,537	0,454	0,408
Смесь гауссовых распределений (признаки)	0,075	211	0,862	0,574	0,587	0,429	0,403
Уорд (признаки)	0,072	209	0,849	0,593	0,554	0,446	0,400

Методы, работающие только с сетью (Leiden, спектральная), дают лучшие сетевые индексы и худшее разделение по признакам: их кластеры связны, но внутри них МО разнородны. Методы только по признакам — наоборот. KEFRiN немного уступает k-средних по признакам (SW 0,094 против 0,106) и заметно выигрывает по сети (MQ 0,462 против 0,408, AVI 0,643 против 0,600). Для типологии, в которой тип должен быть однороден по экономике и связан по сети, выбран KEFRiN. На правиле «слияние» при

всех девяти проверенных K модульность KEFRiN выше, чем у k-средних, а SW отличается не больше чем на 0,02 (`outputs/cluster/icvi_grid.csv`).

6. Типология

6.1. Два уровня

На первом уровне KEFRiN (ξ = 2, правило «слияние») запускался при K от 2 до 8 на всех 2 068 МО. На втором уровне каждый макротип отдельно делился при K от 2 до 5 на подсети из его МО. На обоих уровнях K выбрано правилом из раздела 5.3.

Таблица 4. Выбор числа кластеров (`outputs/typology/icvi_macro.csv`, `icvi_sub.csv`).

Уровень	Голоса SW / CH / MQ	Выбрано
Макротипы, K = 2…8	2 / 2 / 5	2
Подтипы макротипа 1, K = 2…5	2 / 2 / 4	2
Подтипы макротипа 2, K = 2…5	3 / 3 / 5	3

На первом уровне силуэт при K = 2 и K = 3 почти одинаков (0,213 и 0,212), поэтому граница между двумя и тремя макротипами слабая. Сами разбиения при этом устойчивы. На 20 случайных подвыборках по 80% МО та же двухуровневая процедура с теми же числами кластеров воспроизводит итоговые типы: скорректированный индекс Рэнда (adjusted Rand index, ARI; 1 — полное совпадение, 0 — совпадение на уровне случайного) в медиане равен 0,93 для пяти типов (от 0,58 до 0,98) и 0,98 для макротипов (от 0,94 до 1,00; `outputs/typology/stability.csv`). Индексы итогового разбиения на 5 типов: SW 0,115; CH 260; S_Dbw 0,856; AVI 0,713; AVU 0,578; ANUI 0,505; MQ 0,497.

6.2. Типы

Название каждого типа дано по медианам признаков его МО (`outputs/interpret/profile_median.csv`). Медиана по стране приведена для сравнения.

Таблица 5. Типы и их медианные показатели.

	Стареющая глубинка	Удалённая периферия	Города и промышленные центры	Столичные районы	Ресурсные территории	Россия
Код	1.1	1.2	2.1	2.2	2.3	
Число МО	778	585	364	238	103	2 068
Траты жителя в месяц, руб.	22 967	24 784	34 526	50 855	42 829	26 567
Доля продовольствия	46,7%	45,7%	38,5%	31,5%	40,1%	44,1%
Доля общепита	1,6%	2,2%	5,0%	7,9%	4,6%	2,5%
Доля маркетплейсов	18,6%	15,4%	14,9%	13,0%	12,7%	16,0%
Траты к зарплате	45,1%	42,1%	45,9%	38,4%	30,8%	43,4%
Зарплата, руб.	50 571	59 594	76 627	132 047	136 120	61 572
Доля 65+	19,3%	15,0%	15,3%	19,7%	10,2%	17,1%
Доля 0–15 лет	15,9%	20,8%	18,4%	15,4%	21,6%	18,0%
Доступность рынков	343	238	332	578	201	323
Доля горожан	54%	57%	95%	100%	89%	73%
Занятость в обработке	0%	0%	22,7%	6,9%	2,0%	2,1%
Занятость в добыче	0%	0%	0%	0%	24,6%	0%
Занятость в госуправлении	13,3%	13,5%	7,7%	1,9%	5,7%	11,2%
Инвестиции на жителя, тыс. руб.	29	30	78	97	564	40

Медиана доли занятых в обработке и добыче равна 0 у типов, где у большинства МО таких работников нет или раздел не публикуется.

- **Стареющая глубинка** — районы Центра и Поволжья (больше всего в Кировской, Нижегородской, Саратовской, Тверской областях). Самые низкие траты, наибольшая доля продовольствия и маркетплейсов.
- **Удалённая периферия** — районы Сибири, Урала и Дальнего Востока (Красноярский и Алтайский края, Башкортостан, Иркутская и Омская области). Наименьшая после ресурсных территорий доступность рынков, много детей, высокая доля занятых в государственном управлении.
- **Города и промышленные центры** — городские округа, в том числе 48 МО Московской области и 58 из 67 административных центров субъектов, вошедших в типологию. Каждый пятый занятый — в обработке.
- **Столичные районы** — 238 внутригородских территорий Москвы и Санкт-Петербурга. Самые высокие траты, наибольшие доли общепита и транспорта.

- **Ресурсные территории** — ХМАО, Якутия, ЯНАО, Сахалин. Четверть занятых — в добыче, инвестиции на жителя в 14 раз выше медианы страны, траты составляют наименьшую долю зарплаты.

6.3. Описание типов формальными понятиями

Анализ формальных понятий (formal concept analysis, Ganter, Wille, 1999) описывает группу объектов набором признаков, которыми все они обладают. Формальный контекст — таблица «МО × двоичный атрибут». Атрибуты получены из признаков по терцилям страны: «доля общепита: верхняя треть», «доля детей: нижняя треть» и т. д.; треть определяется по процентильному рангу, равные значения получают один ранг. Формальное понятие — пара «объём, содержание»: объём — множество МО, содержание — множество атрибутов, которые есть у всех МО объёма, причём других МО с этими атрибутами нет.

Для каждого типа отбираются 8 атрибутов с наибольшим подъёмом (доля МО типа с атрибутом, делённая на долю по стране), по ним строится решётка всех формальных понятий (пакет fcapy), и выбирается понятие, чей объём лучше всего совпадает с типом по мере F1 — среднему гармоническому точности (доля объёма, попавшая в тип) и полноты (доля типа, попавшая в объём).

Таблица 6. Описания типов (`outputs/interpret/fca_descriptions.json`).

Тип	Содержание понятия	Точность	Полнота	F1
Стареющая глубинка	доля прочих трат: нижняя треть	0,76	0,68	0,72
Удалённая периферия	доля детей: верхняя треть	0,63	0,71	0,67
Города и промышленные центры	население: верхняя треть; платные услуги на жителя: верхняя треть	0,75	0,62	0,68
Столичные районы	доля горожан, зарплата, доля общепита, уровень трат, доля транспорта, доступность рынков, доля прочих трат — верхняя треть; доля продовольствия — нижняя треть	0,92	0,97	0,94
Ресурсные территории	занятость в добыче, рабочих мест на жителя, зарплата, доля прочих трат — верхняя треть; доля 65+, траты к зарплате — нижняя треть	0,88	0,64	0,74

6.4. Пороговые правила

Дерево решений глубины 3 (не менее 20 МО в листе), обученное различать пять типов по исходным признакам, правильно относит 80% МО (`outputs/interpret/tree_rules.txt`). Первое разбиение дерева — доля общепита в тратах 3,5%: ниже порога лежат оба периферийных типа, выше — города, столичные районы и ресурсные территории. Периферию дальше делят доля детей (18,8%) и доступность рынков (209), городские типы — доля занятых в обработке (5,7%) и доля общепита (7,0%).

6.5. Сверка с категориями МО

Лаборатория СберИндекса в итогах потребления 2025 года разделяла МО на сельские территории, пригороды агломераций, центры регионов, добывающие территории и наукограды. Для сверки категории определены по справочнику и Росстату (`outputs/interpret/lab_categories_by_type.csv`):

- 99% столичных районов — внутригородские территории Москвы и Санкт-Петербурга;
- 66% ресурсных территорий — МО с долей занятых в добыче не меньше 15%;
- 58 из 67 административных центров субъектов, вошедших в типологию, — в типе «города и промышленные центры», ещё 7 — в ресурсных территориях.

Сельские территории (доля горожан меньше 30%) по типам почти не выделяются: доля горожан известна только для 71% МО панели, и среди них мало сельских районов.

6.6. Внешняя проверка индексом мобильности

Индекс мобильности СберИндекса — медиана по жителям МО среднего расстояния от центра их покупок до точки каждой покупки, км. Он опубликован для 297 МО Северо-Западного федерального округа и в построении типов не участвовал. 278 из них сопоставлены с типологией по полному названию МО внутри регионов округа (`outputs/interpret/mobility_by_type.csv`).

Таблица 8. Медиана индекса мобильности по типам, 2024 год.

Тип	Число МО	Мобильность, км
Стареющая глубинка	92	0,53
Удалённая периферия	32	0,71
Города и промышленные центры	50	2,89
Столичные районы	96	4,80
Ресурсные территории	8	1,45

Типы различаются по мобильности: тест Краскела — Уоллиса $H = 180{,}7$, $p < 10^{-37}$; тип объясняет 65% дисперсии рангов мобильности ($\eta^2 = 0{,}65$). Жители глубинки и периферии покупают в радиусе около полукилометра — в пределах своего населённого пункта; жители городов и столичных районов — в радиусе 3–5 км.

7. Динамика

Типология построена один раз по окну январь — декабрь 2024 года. В каждом из 12 окон МО относится к типу с ближайшим центром в пространстве признаков; признаки стандартизуются по всем окнам сразу, поэтому центры и МО разных окон сравнимы. Метки типов в разных окнах совпадают по построению.

Таблица 7. Переходы между типами: строка — окно с концом в январе 2024 года, столбец — в декабре 2024 года (`outputs/dynamics/transitions_first_last.csv`).

из в	1.1	1.2	2.1	2.2	2.3
1.1 Стареющая глубинка	620	0	4	1	0
1.2 Удалённая периферия	128	509	31	0	0
2.1 Города и промышленные центры	2	0	354	0	0
2.2 Столичные районы	0	0	1	238	0
2.3 Ресурсные территории	0	6	9	0	133

От окна к окну тип сохраняют 98,8% МО. За год тип сменили 216 МО; 128 из них перешли из удалённой периферии в стареющую глубинку. Это пограничные МО: в окне, закончившемся в январе 2024 года, отношение их расстояний до центров периферии и глубинки в медиане равнялось 0,97 (у оставшихся в периферии — 0,83), и у 90% из них оно превышало 0,9 (у оставшихся — у 17%). По отдельным признакам перешедшие и оставшиеся менялись почти одинаково: доля маркетплейсов выросла на 4,7 и 4,3 процентного пункта. Переход отражает сумму малых сдвигов у МО на границе двух типов.

Флаг расхождения ставится МО, которое сменило тип за год, или у которого расстояние до центра своего типа растёт быстрее, чем у 95% МО (наклон линейного тренда расстояния по 12 окнам). Флаг получили 312 МО.

8. Продукт

Для каждого из 2 068 МО по окну 2024 года.

- **Сопоставимые МО** — 15 ближайших по евклидову расстоянию в пространстве 30 стандартизованных признаков. Отдельно — до 5 ближайших из тех, до которых не больше 300 км по дорогам.
- **Потенциал** — место МО среди 16 (МО и 15 сопоставимых) по шести показателям: траты жителя, рост трат 2024 к 2023 году, доли общепита и маркетплейсов, траты к зарплате, зарплата. Приводится МО с лучшим значением.
- **Опыт** — три сопоставимых МО с наибольшим ростом трат за год и три признака, по которым каждое из них сильнее всего отличается от выбранного МО (разность стандартизованных значений).
- **Расхождение** — флаг и траектория типа по 12 окнам.

Пример — Комсомольск-на-Амуре (город и промышленный центр). Сопоставимые МО: Братск, Артёмовский, Ачинск, Находкинский, Нижний Тагил и ещё 10 промышленных городов Сибири, Урала и Дальнего Востока. По тратам жителя (43 257 руб. в месяц) он первый из 16, по росту трат (+17%) — восьмой; наибольший рост среди сопоставимых — у Бийска (+21%).

Продукт опубликован как датасет `outputs/dataset/mo_peers.csv` и JSON-карточка на каждый МО `outputs/dataset/api/<territory_id>.json`. Ключ — `territory_id` справочника СберИндекса, лицензия — CC BY-SA 4.0 с указанием источника «СберИндекс». Датасет пересчитывается одной командой при выходе нового месяца данных.

9. Обсуждение

Типология из пяти типов и продукт на её основе дают то, чего нет в сравнении со средним по региону: для любого МО — полтора десятка МО со схожей экономикой из разных регионов и понятные

ориентиры, у кого учиться. Типы экономически осмысленны: они совпадают с категориями, которыми пользуется лаборатория СберИндекса (столичные районы, добывающие территории, центры регионов), подтверждаются независимым индексом мобильности (тип объясняет 65% дисперсии рангов) и описываются короткими формальными понятиями и пороговыми правилами.

Главный методический результат — правило выбора числа кластеров для атрибутированных сетей: на синтетике SW, CH и MQ находят верное число групп, а S_Dbw, AVI, AVU и ANUI монотонны по K и для этого непригодны. Второй — вес сети в KEFRiN: при $\xi = 2$ сеть улучшает сетевые индексы без потерь в разделении по признакам.

Развивать работу стоит в трёх направлениях. Первое — более длинные ряды трат: 24 месяца не позволяют надёжно оценить сезонность и опережение одних МО другими. Второе — матрица потоков трат между МО (где тратят жители): она дала бы правило ребра, основанное на реальных экономических связях. Третье — новостной слой для МО с флагом расхождения, объясняющий, что произошло.

Ограничения. Оценка трат СберИндекса основана на данных одного банка; его доля на рынке различается по регионам, поэтому межрегиональные сравнения уровня трат надёжнее внутри типа. Показатели Росстата доступны не для всех МО и заполняются медианой. На первом уровне индексы почти одинаково оценивают два и три макротипа (раздел 6.1), хотя сами разбиения устойчивы к выбору подвыборки МО.

10. Воспроизводимость

```
uv sync
uv run mopeers all
```

Все гиперпараметры — в `configs/base.yaml`, названия и описания типов — в `configs/types.yaml`. Исходные данные скачиваются из официальных источников, пакет Data Sense проверяется по SHA-256. Код алгоритмов жюри (KEFRiN, генератор синтетики, метрики Pattern) скачивается с зафиксированных коммитов. Случайные запуски фиксируются `seed: 0`.

Литература

1. Shalileh S., Mirkin B. Community partitioning over feature-rich networks using an extended k-means method // Entropy. 2022. Vol. 24, No. 5. P. 626.
2. Ganter B., Wille R. Formal Concept Analysis: Mathematical Foundations. Springer, 1999.
3. Traag V. A., Waltman L., van Eck N. J. From Louvain to Leiden: guaranteeing well-connected communities // Scientific Reports. 2019. Vol. 9. 5233.
4. Rousseeuw P. J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis // Journal of Computational and Applied Mathematics. 1987. Vol. 20. P. 53–65.
5. Caliński T., Harabasz J. A dendrite method for cluster analysis // Communications in Statistics. 1974. Vol. 3, No. 1. P. 1–27.
6. Halkidi M., Vazirgiannis M. Clustering validity assessment: finding the optimal partitioning of a data set // Proceedings of IEEE ICDM. 2001. P. 187–194.
7. Newman M. E. J. Modularity and community structure in networks // PNAS. 2006. Vol. 103, No. 23. P. 8577–8582.

8. Доклад С. Шалилеха и Е. Антонова на AI Journey 2025 о поведении индексов качества кластеризации атрибутированных сетей на синтетических данных (сообщение канала «Команда СберИндекса» от 03.12.2025).